

# 中国科学院研究生院

## 硕士学位论文

面向确认任务的人脸识别技术研究

---

杨非

指导教师 赵德斌 教授

中国科学院计算技术研究所

申请学位级别 工学硕士 学科专业名称 计算机应用技术

论文提交日期 2006 年 5 月 论文答辩日期 2006 年 6 月

培养单位 中国科学院计算技术研究所

学位授予单位 中国科学院研究生院



## 摘 要

自动人脸识别技术包含人脸辨识和人脸确认两类不同的任务。近年来，自动人脸识别技术取得了很大的进展。但是大多数研究工作集中于人脸辨识领域，只有少数文献探讨人脸确认问题，而且没有对人脸确认的特殊性进行深入研究。基于此，本文重点针对人脸确认问题进行了研究，主要工作包括：

(1) 集中讨论了人脸确认任务的特殊性问题，从多个方面对人脸确认与人脸辨识进行了比较，并推导了“首选识别率”、“等错误率”以及“最小错误率和”之间的数学关系，提出了计算系统的辨识和确认性能的数学模型，并使用该模型在理论上证明了：当用户的类内和类间相似度值的分布发生变化时，系统的确认性能和辨识性能遵循不同的变化规律。也就是说：一种辨识性能好的算法，未必具有好的确认性能，反之亦然。

(2) 探讨了确认系统中的阈值设定策略。针对图像表观变化导致的相似度偏移问题，本文讨论了解决该问题的两种方法：用户特定阈值和分值归一。我们通过理论分析，证明了在每个用户只有一幅训练图像时，用户特定阈值与 Z-Norm 分值归一方法的效果等价，并通过实验验证了这一结论。我们在 FERET 和 CAS-PEAL 人脸库上使用多种分类算法进行实验，实验结果表明，与统一阈值方法相比，在多数情况下分值归一方法能有效的改进人脸确认系统的性能。

(3) 研究了基于 SVM 的人脸确认算法。本文在 PCA 和 LDA 子空间中，求取样本的差向量，再使用 SVM 分类器对类内差和类间差进行分类。我们在 FERET 人脸库上将 SVM 方法同多种基准算法进行比较，实验表明：在 PCA 子空间中，使用 SVM 方法对类内和类间差向量进行分类，与传统的直接计算向量相似度相比，能有效提高系统的确认性能，而在 LDA 子空间中，对差向量的 SVM 分类方法不能明显改进确认性能。

(4) 提出了一种新的基于局部二值模式的 SVM 人脸确认算法 (LBP-SVM)。该方法首先提取图像的 LBP 特征，然后计算出局部统计相似度，并将所有的局部相似度连接成相似度向量，最后使用 SVM 分类器对类内相似度向量和类间相似度向量进行分类。对于 FERET 人脸库的所有测试子集，LBP-SVM 方法的确认性能都好于不加权的 LBP 算法。

本文在人脸确认问题上的初步研究结果使我们进一步认识到：尽管确认与辨识在核心技术上是相通的，但确认问题的确存在其特殊性，尤其是相似度偏移问题，应该引起更多的关注。

**关键词：** 人脸确认，分值归一，支持向量机



## Abstract

Automatic Face Recognition (AFR) includes two tasks: *identification* and *verification*. It has received large progress in recent years. However, most research focuses on face identification. Only a few papers concern the verification of faces, yet have little deep research on its special characteristics. This thesis deals with the face verification. The main work of this thesis is as follows:

(1) The specialty of face verification techniques is investigated in this thesis. We compare face verification with face identification from several aspects, and deduce several mathematical relations among the Rate of Top One Match, the Equal Error Rate, and the Minimum Total Error Rate. This thesis presents a mathematical model to compute the identification and verification performance, and uses this model to theoretically prove that the performances of identification and verification follow different rules of change when the distribution of intra and extra class similarity scores change. It suggests that an algorithm with good identification performance does not imply good verification performance, and vice versa.

(2) The thresholding approach in verification systems is studied. To solve the “score variation” problem caused by appearance variation of images, this thesis investigates two methods, Subject Specific Threshold (SST) and Score Normalization (SN). Through theoretical analysis and experiments, we prove that SST and Z-Norm methods can get approximately equivalent effects in case that every subject in the system has only one training image. We perform experiments with multiple methods in both the FERET and CAS-PEAL face databases. The results reveal that SN can improve the performance of face verification system in most cases compared with the unified threshold method.

(3) The SVM based face verification algorithm is investigated in the thesis. We firstly compute the difference vectors in PCA and LDA subspace, then use SVM method to classify intra and inter class difference vectors. The SVM method is compared with several baseline methods using the FERET database. The results show that SVM method can improve the verification performance in PCA subspace. However, it can not achieve better verification performance in LDA subspace.

(4) This thesis proposes a new face verification method based on Local Binary Pattern (LBP) and SVM. This method first extracts the LBP features from face images, then computes the local region similarities and concatenates all the local similarities into a similarity vector. Finally, an SVM classifier is used to classify the intra and inter class

similarity vectors. In all the probe sets of the FERET face database, LBP-SVM method can achieve better performance than non-weighted LBP algorithms for face verification.

The research results in this thesis reveal that, although verification and identification are similar in core techniques, verification has its unique characteristics. In addition, the “score variation” problem requires more attention.

**Key words:** face authentication, score normalization, support vector machines

# 目 录

摘 要.....	I
Abstract.....	III
目 录.....	V
第 1 章 绪论.....	1
1.1 人脸识别技术应用背景 .....	1
1.2 人脸识别技术主要研究方法 .....	2
1.3 本文研究内容和主要贡献 .....	4
第 2 章 人脸确认问题分析.....	5
2.1 人脸辨识和人脸确认的比较 .....	5
2.1.1 应用背景 .....	5
2.1.2 分类器设计 .....	6
2.1.3 性能评价标准.....	6
2.2 确认性能的若干性质分析 .....	8
2.3 典型人脸确认评测协议简介 .....	16
2.3.1 FERET 评测 .....	16
2.3.2 FRVT 评测 .....	17
2.3.3 XM2VTS 评测.....	20
2.4 本章小结 .....	22
第 3 章 分值归一方法 .....	23
3.1 相似度偏移问题.....	23
3.2 用户特定阈值 .....	24
3.3 分值归一方法 .....	25
3.4 用户特定阈值和分值归一实验 .....	26
3.5 本章小结 .....	29
第 4 章 基于 SVM 的人脸确认方法 .....	31
4.1 统计学习理论和支持向量机 .....	31
4.1.1 统计学习理论.....	31
4.1.2 最优分类面 .....	32
4.1.3 广义最优分类面.....	33

4.1.4	支持向量机 .....	34
4.2	SVM 人脸确认算法概述 .....	35
4.3	基于差空间的 SVM 确认算法 .....	36
4.4	基于局部二值模式的 SVM 确认算法 .....	38
4.5	本章小结 .....	40
<b>第 5 章</b>	<b>总结 .....</b>	<b>41</b>
<b>参考文献 .....</b>		<b>43</b>
<b>致    谢 .....</b>		<b>xlvi</b>



# 第1章 绪论

## 1.1 人脸识别技术应用背景

基于生物特征的身份认证技术，是依据人体本身所固有的生理特征或行为特征，利用图像处理技术（或其他数字信号处理技术）和模式识别技术，来实现身份鉴别或验证。可用来验证身份的生物特征包含人脸、指纹、掌纹、虹膜、视网膜、语音、签名、步态等等。

传统的身份认证方法主要借助身份标识物品（如钥匙、证件、ATM 卡等）和身份标识知识（如用户名和密码），一旦证明身份的标识物品和标识知识被盗或遗忘，其身份就容易被他人冒充。生物特征认证技术具有不会遗忘、不易窃取和伪造、随身携带、随时随地可用等优点，比传统的身份认证方法更加安全和方便。

自 2001 年美国“9·11”恐怖袭击发生以来，各国都投入大量人力物力发展各项安全技术。在政府和企业的推动下，生物特征认证技术取得了巨大进展，并开始广泛应用于安全和商业领域。据国际生物认证组织（IBG）统计，2005 年全球生物特征认证技术的市场总额为 15.4 亿美元。预计到 2010 年将达到 57 亿美元[1]（如图 1-1）。




图 1-1 2006-2010 生物特征认证技术市场总额预测（图片引自 IBG 报告[1]）

人脸识别技术是最主要的生物特征身份认证技术之一。在各种生物特征认证技术中，人脸识别技术的市场份额仅次于指纹识别技术。预计在 2006 年，人脸识别技术的市场份额将占市场总额的 19%[1]（如图 1-2）。人脸识别技术在公安、司法、金融、民航、海关、保险等领域具有极为广阔的应用前景。与其他生物特征认证技术相比，人脸识别技术具有以下优势[2]：

（1）人脸识别具有快捷、非接触的特点，对用户友好。人脸是人们在日常生活中辨认他人的最常用的特征。利用人脸特征进行身份验证最易被人们接受。




图 1-2 2006 年各项生物认证技术市场份额预测（图片引自 IBG 报告[1]）

(2) 存在丰富的现有数据。社会上具有各种大型的人脸数据库，如公安部门的身份证照片数据库，学校里的学生学籍数据库等等。在各种身份证明材料中，一般也都包含标准的正面人脸照片。而其他生物特征则缺少大规模的现有数据。

(3) 数据采集方便，采集设备成本低廉。目前，普通数码相机、数码摄像机和照片扫描仪等摄像设备在普通家庭的日益普及进一步增加了其可用性。

(4) 方便事后追踪。普通人可以对人脸认证系统的结果进行判定。而上述其他生物特征一般只能通过专家认定。

(5) 人脸识别可以在隐蔽的条件下进行，适用于安全监控。

## 1.2 人脸识别技术主要研究方法

最近 20 年来，人脸识别领域取得了大量进展[3][4][5]。一些典型人脸识别算法有：

### (1) 基于几何特征的方法

Bledsoe[6]提出了基于几何特征的方法。这种方法先定位面部的主要器官，如眼睛、鼻子、嘴、下巴和眉毛等，然后从中选择一组反映他们之间的距离、角度、区域形状等的结构特征，组成特征向量，再选定某种距离作为度量。这类方法只利用了面部的结构信息，没有利用纹理信息。Roder 研究表明几何特征提取的精确性不容乐观[7]。

### (2) 基于模板匹配的方法

R. Brunelli[8]提出了基于模板匹配的方法。主要通过计算模板和图像灰度的相关性来进行识别。可以将整幅图像作为一个模板，也可将眼睛、鼻子、嘴部等局部器官单独定义模板，单独进行匹配。这种方法充分利用了面部图像的纹理信息，但对光照、姿态和表情变化比较敏感[9]。

### (3) 基于子空间的方法

M. Turk 和 A. Pentland[10]提出 Eigenface 算法。该算法对人脸图像进行主成分分析 (Principal Component Analysis), 得到由一组特征脸 (Eigenface) 张成的人脸子空间。将新的人脸图像向该子空间进行投影, 计算出对应于各特征人脸的权值, 以权值向量之间的距离作为判定人脸图像相似程度的依据。

Eigenface 方法提取了最富表达性的特征 (Most Expressive Features), 适用于人脸的编码和压缩。为了提取最富区分性的特征 (Most Discriminant Features), 提出了 Fisherface 方法[11][12], Fisherface 方法以样本的可分性为目标, 寻找一组线性变换使每类的类内离散度最小, 并使类间离散度最大。当存在大量有代表性的训练样本时, Fisherface 性能要优于 Eigenface 方法[13]。

#### (4) 局部特征分析

局部特征分析技术 (Local Feature Analysis, LFA) 是由洛克菲勒大学的 Atick 等人提出的[14]。LFA 在本质上是一种基于统计的低维对象描述方法, LFA 在全局 PCA 描述的基础上提取出局部的特征, 同时保留了全局的拓扑信息, 从而具有更佳的描述和判别能力。LFA 技术已商业化为 FaceIt 系统。

#### (5) 弹性图匹配方法

弹性图匹配算法 (Elastic Bunch Graph Matching) 由 L. Wiskott 等人[15]提出。弹性图匹配算法基于对人脸图像的几何特征和灰度分布进行小波纹理分析, 利用了人脸的结构和灰度分布信息, 具有较好的识别效果。但由于该算法需要对图像进行小波分析, 因而时间复杂度较高。

#### (6) 支持向量机方法

支持向量机 (SVM) 是一种基于统计学习理论的分类算法, 具有良好的分类性能和推广能力。SVM 是一种两类问题分类器。在人脸识别领域, 使用差空间[37]、一对一[38]、一对多[40]三种分类策略实现人脸辨识和确认。

#### (7) 基于神经网络的方法

利用人工神经网络进行人脸图像的识别要先通过训练将视觉刺激形成某种内部表示, 并分散存储于某种神经结构中。使用人工神经网络识别时所进行的搜索过程, 也类似于人脑的联想过程。使用该方法的一个优点在于, 当人脸图像有缺失或存在小的形变时, 也能够有效地进行识别; 但该方法训练过程复杂且算法收敛慢, 同时神经网络的容量也存在限制。

#### (8) 3D 人脸识别

从知识表达完备性的角度来看, 3D 人脸表面模型由于不仅反映了人脸图像平面内的结构信息, 同时还保存了人脸的深度方面的结构信息, 因此 3D 人脸模型是人脸的较完备描述。但由于目前技术手段的限制, 真实人脸的 3D 数据难于获取。

### 1.3 本文研究内容和主要贡献

本文主要研究面向确认任务的人脸识别技术。人脸确认是人脸识别领域的重要问题之一。但是目前只有少数文献专门探讨人脸确认问题。对于人脸确认的特殊性，缺少相应的研究和认识。因此，本文专门研究人脸确认问题，分析人脸确认问题相对于其他人脸识别技术问题的独特特点。

本文第 2 章将人脸确认与人脸辨识在应用背景、分类器设计、性能评价等方面进行综合比较，推导了“首选识别率”、“等错误率”以及“最小错误率和”之间的数学关系。我们提出了计算系统的辨识和确认性能的数学模型，并使用该模型在理论上证明了，当用户的类内和类间相似度分值的分布发生变化时，系统的确认性能和辨识性能遵循不同的变化规律。也就是说：一种辨识性能好的算法，未必具有好的确认性能。反之，一种确认性能好的算法，未必具有好的辨识性能。最后，我们还总结了 FERET、FRVT 和 XM2VTS 三个典型的人脸识别技术评测中，确认性能评测协议的设计特点。

本文第 3 章主要研究人脸确认系统的阈值设定策略。我们分析了“相似度偏移问题”的成因及其对系统性能的影响，讨论了该问题的两种解决方法：“用户特定阈值法”和“分值归一法”。我们通过数学推导，证明了在每个用户只有一幅训练图像时，“用户特定阈值法”与 Z-Norm 分值归一方法的效果等价。这一结论在 FERET 人脸库上通过实验得到了验证。我们在 FERET 和 CAS-PEAL 人脸库上使用多种分类算法进行实验，实验结果表明，与统一阈值方法相比，在多数情况下分值归一方法能有效的改进人脸确认系统的性能。

本文第 4 章研究基于 SVM 的人脸确认算法。我们在 PCA 和 LDA 子空间中，求取样本的差向量，再使用 SVM 分类器对类内差和类间差进行分类。我们在 FERET 人脸库上将 SVM 方法同多种基准算法进行比较，实验表明：在 PCA 子空间中进行 SVM 分类能有效提高系统的确认性能，而在 LDA 子空间中再使用 SVM 分类器不能得到明显的性能改善。在第 4 章中，我们还提出了一种新的基于局部二值模式的 SVM 人脸确认算法（LBP-SVM）。该方法首先提取图像的 LBP 特征，然后计算出局部相似度，再将所有的局部相似度连接成相似度向量，最后使用 SVM 分类器对类内相似度向量和类间相似度向量进行分类。对于 FERET 人脸库的所有测试子集，LBP-SVM 方法的确认性能都要好于不加权的 LBP 算法。

## 第2章 人脸确认问题分析

人脸确认是人脸识别领域的重要问题之一。与人脸辨识问题相比，人脸确认问题在应用背景、分类器设计、性能评价等方面有着显著不同。本章我们将人脸确认与人脸辨识进行比较，从性能评价函数入手，对人脸确认系统的性能进行数学分析。我们通过数学推导和实验得出，当用户的类内和类间相似度分值的分布发生变化时，系统的确认性能和辨识性能遵循不同的变化规律。因此，在比较两种算法的辨识和确认性能时，可能得到完全相反的结果。在本章中，我们还介绍 FERET、FRVT 和 XM2VTS 三个典型的人脸识别技术评测，总结它们的确认性能评测协议的设计特点。

### 2.1 人脸辨识和人脸确认的比较

人脸识别包含辨识（Identification）和确认（Verification/Authentication）两类不同的问题。本节将从应用背景、分类器设计、性能评价标准等方面比较人脸辨识问题和人脸确认问题的不同。

#### 2.1.1 应用背景

在人脸辨识（Identification）应用中，一幅未知身份的人脸图像被提交给人脸辨识系统，系统将该图像同与系统中已知身份的人脸图像进行比较，给出最相似一个或多个人的身份。典型的人脸辨识系统如用于网上追逃的照片比对系统，数据库中存储了所有嫌犯的人脸图像，可疑人员的图像送入该系统中进行比对，按相似程度返回一组嫌犯，再由公安人员加以确认。

人脸确认（Verification）系统除了要采集用户的人脸图像外，还要求用户通过 IC 卡、键盘或鼠标操作提供一个身份，系统将采集到的人脸图像同该身份的人脸模型进行比较，判断人脸图像是否符合该身份，即接受（accept）还是拒识（deny）。典型的人脸确认应用包括考勤系统、门禁系统或 ATM 自动柜员机验证系统。

人脸辨识系统需要将输入人脸图像同所有人的人脸进行比较；而人脸确认系统只需要与所声明身份的人脸比较即可。典型的人脸辨识问题是一个“闭问题”，即假定测试人脸的身份已存在于系统数据库中。而典型的人脸确认问题是一个“开问题”，测试者可以是系统注册的合法用户，也可能是从未出现过的伪冒者。所以人脸确认系统必须处理各种伪冒者的情况。

在人脸识别领域，还有很多应用并不属于典型的辨识问题或典型的确认问题，而是两者的结合。在这些应用中，需要先判断输入人脸图像是否是系统的合法用户，如果是，给出识别结果，如果不是，加以拒绝。这类问题称为“开集识别”。例如，在基于人脸识别的计算机登录系统中，要先判断当前登陆者是否是系统用户，如果是系统

用户，再识别出用户身份，并进入该用户访问界面。在本章中，我们主要研究典型的人脸辨识和人脸确认问题。我们的研究结论也可以推广到开集识别系统。

### 2.1.2 分类器设计

典型的人脸辨识问题是一个多类问题，如图 2-1(a)所示。类别  $C_p$  为第  $p$  个人的所有人脸图像，这些图像包含了各种光照、表情、姿态的变化。整个人脸图像空间根据用户身份划分成了多个类。人脸辨识问题，即对给定的一幅人脸图像，确定所属的类别。




图 2-1 辨识和确认的分类方法

典型的人脸确认问题是一个两类问题，如图 2-1(b)所示。对于给定的身份  $C_p$ ，系统要决定输入人脸图像是不是属于类别  $C_p$ 。

在确认问题中，不同用户的人脸模型可能具有不同的特点，每个用户需要使用不同的决策准则进行判定。一些用户的人脸图像在光照、表情变化时可能发生更显著的改变，从而需要更宽松的决策分类面。本文第 3 章将详细讨论这一问题。

### 2.1.3 性能评价标准

评测算法的辨识性能主要采用累积识别率曲线[16]，评测算法的确认性能主要采用 ROC 曲线[17]，下面分别加以介绍。

#### 1. 累积识别率曲线

评测辨识性能主要采用累积识别率曲线（Cumulative Match Scores, CMS）[16]，如图 2-2 所示，横坐标表示阶数（Rank） $k$ ，纵坐标表示累积正确识别率，即真实身份出现在前  $k$  个辨识结果中的百分比。把阶数  $k$  等于 1 时的累积识别率定义为首选识别率（Rate of Top 1,  $R_{T1}$ ）。当参考集合的规模增大时，前  $k$  阶累积识别率会随之下降。所以只有在指定参考集合的大小时，累积识别率的比较才有意义。

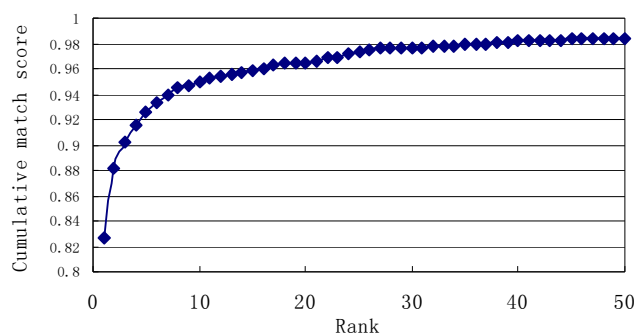


图 2-2 累积识别率曲线

## 2. ROC 曲线

确认系统对样本的错误分类有两种，一种是将属于不同人的脸判断为属于同一人的脸，称之为错误接受（False Acceptance, FA）。另一种是将属于同一人的脸判断为属于不同人，称之为错误拒绝（False Rejection, FR）。错误接受率（FAR）和错误拒绝率（FRR）的定义如下：

$$FAR = \frac{\text{number of FAs}}{\text{number of impostor accesses}}, \quad FRR = \frac{\text{number of FRs}}{\text{number of client accesses}}$$

正确确认率（Probability of Correct Verification, PCV），也称为击中率（Hit Rate），定义为属于同一人的脸正确通过确认的比例，所以

$$PCV = 1 - FRR$$

对于人脸确认系统，FAR、FRR（或 PCV）与阈值的大小有关。改变系统的阈值，即可得到一系列对应的 FAR、FRR（或 PCV）。以 FAR 为横坐标，以 PCV 为纵坐标将这些对应点依次连接，得到系统的 ROC 曲线（Receiver Operating Characteristic）[17]，如图 2-3 所示。ROC 曲线是衡量确认性能的常用标准。

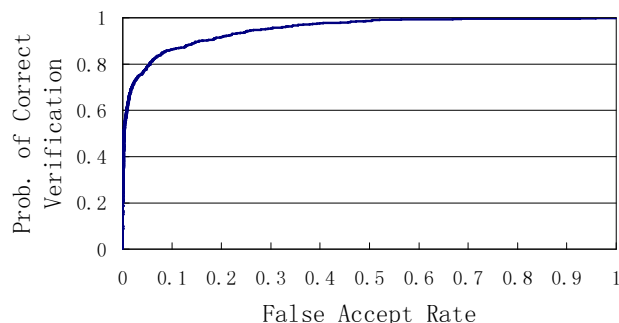


图 2-3 ROC 曲线

将 FAR 和 FRR 相等时对应的错误率，定义为等错误率（Equal Error Rate, EER）。等错误率与参考集的规模无关。

$$EER = FAR(t) | t : FAR(t) = FRR(t)$$

### 3. 其他确认评测指标

决策代价函数（Decision Cost Function, DCF）结合了 FRR 和 FAR 两种评价参数：

$$DCF = Cost(FR) \cdot P(client) \cdot FRR + Cost(FA) \cdot P(imposter) \cdot FAR$$

如果错误拒绝的代价  $Cost(FR)$  和错误接受的代价  $Cost(FA)$  都设为 1，且假定用户和伪冒者出现的概率都为 1/2，则得到决策代价函数的特殊形式：

$$HTER = \frac{FAR + FRR}{2}$$

以及

$$TER = 2 \times HTER = FAR + FRR。$$

将 TER 的最小值定义为最小错误率和（ $TER_{\min}$ ）。 $TER_{\min}$  和  $HTER_{\min}$  都是衡量确认性能的常用标准。

## 2.2 确认性能的若干性质分析

上节中介绍了辨识性能的评测指标首选识别率（ $R_{TI}$ ），以及确认性能的评测指标等错误率（EER）和最小错误率和（ $TER_{\min}$ ）。本节我们从这些性能评价函数入手，通过数学推导和实验，分析  $R_{TI}$ 、EER、 $TER_{\min}$  的数学性质。




图 2-4 系统的类内和类间相似度分布

属于同一个人的人脸图像之间的相似度，称为类内相似度；属于不同人的人脸图像之间的相似度，称为类间相似度。如图 2-4 所示，其中  $p(s | \lambda)$  和  $p(s | \bar{\lambda})$  分别表示类内和类间相似度地分布函数。当系统的阈值为  $t$  时，错误接受率（FAR）和错误拒绝率（FRR）可以表示为：

$$FAR(t) = \int_t^{+\infty} p(s | \bar{\lambda}) ds \quad FRR(t) = \int_{-\infty}^t p(s | \lambda) ds$$

因为概率密度函数  $p(s | \lambda) \geq 0$ ， $p(s | \bar{\lambda}) \geq 0$ ，所以  $FAR(t)$  为  $t$  的单调递减函数， $FRR(t)$  为  $t$  的单调递增函数。

在评测系统的辨识和确认性能时，设参考集为  $G = \{g_i\}$ ， $(i = 1, \dots, I)$  其中  $I$  表示参考集  $G$  中的用户数。假定每个用户在参考集中只有一幅图像。设测试集为  $P = \{p_j\}$ ，



$(j=1, \dots, J)$ ，其中  $J$  表示测试集  $P$  中的图像数。设相似度矩阵为  $S = \{s_{ij}\}$ ， $s_{ij}$  为参考图像  $g_i$  与测试图像  $p_j$  的相似度。

前  $N$  阶累积识别率算法如图 2-5 所示。

图 2-5 前  $N$  阶累积识别率算法

```

初始化累积识别率数组: Rank[1,...,N] = 0
for each  $p_j, (j=1, \dots, J)$  {
    在  $G$  中找到  $g_m$ ，使得  $\text{id}(g_m) = \text{id}(p_j)$ ；
    统计  $r = |\{g_k : s_{kj} \geq s_{mj}\}|$ ，Rank[r]++;
}
Rank[1,...,N] /= I

```

等错误率算法如图 2-6 所示。

图 2-6 等错误率算法

```

(1) 统计 (a)类内相似度分布直方图 Hist_Intra[1,...,K]
        (b)类间相似度分布直方图 Hist_Inter[1,...,K] (K 表示直方图 Bin 的个数)
(2) 以所有 Bin 的边界点  $t_i, (i = 0, \dots, K)$  为阈值。
    每个阈值点  $t_i$  的 FRR，为类内相似度直方图 Hist_Intra[] 小于  $t_i$  的所有区间的和：
    for ( $i = 1; i \leq K; i++$ )
        FRR[i] = sum(Hist_Intra[1,...,i-1]);
(3) 每个阈值点  $t_i$  的 FAR，为类间相似度直方图 Hist_inter[] 大于  $t_i$  的所有区间的和：
    for ( $i = 1; i \leq K; i++$ )
        FAR[i] = sum(Hist_Inter[i,...,K]);
(3) 找到位置  $t_0$ ，使得 FAR[  $t_0$  ] 与 FRR[  $t_0$  ] 最接近
    则 EER = (FRR[  $t_0$  ] + FAR[  $t_0$  ]) / 2

```

下面我们通过数学推导和实验，分析 EER、 $TER_{\min}$  和 TMS 数学性质。

**命题 1. 等错误率 (EER) 与最小错误率和 ( $TER_{\min}$ ) 具有下面关系：**

$$EER \leq TER_{\min} \leq 2EER \quad \text{及} \quad \frac{1}{2}TER_{\min} \leq EER \leq TER_{\min} \leq 1$$

证明：假定在  $t_0$  处  $EER = FAR(t_0) = FRR(t_0)$ ，在  $t_1$  处  $TER_{\min} = FAR(t_1) + FRR(t_1)$ 。

(1) 先证  $EER \leq TER_{\min}$

反证法，若  $EER > TER_{\min}$ ，即  $FAR(t_0) = FRR(t_0) > FAR(t_1) + FRR(t_1)$ ，

因为 FAR 和 FRR 非负，所以  $FAR(t_0) > FAR(t_1)$  且  $FRR(t_0) > FRR(t_1)$ 。

若  $t_0 \leq t_1$ ，又  $FAR(t_0) > FAR(t_1)$ ，这与 FRR 单调递增矛盾。

若  $t_0 > t_1$ ，又  $FRR(t_0) > FRR(t_1)$ ，这与 FAR 单调递减矛盾。

所以  $EER \leq TER_{\min}$  得证。

(2) 再证  $TER_{\min} \leq 2EER$

由  $TER_{\min}$  的定义可以直接得到  $TER_{\min} \leq FAR(t_0) + FRR(t_0) = 2EER$ ，得证。

(3)  $TER_{\min} \leq 1$  必然成立，因为

当  $t = -\infty$  时， $FAR = 1$ ， $FRR = 0$ ，所以  $TER(t = -\infty) = 1$ 。当  $t = +\infty$  时， $FAR = 0$ ， $FRR = 1$ 。所以， $TER(t = +\infty) = 1$ 。所以  $TER_{\min} \leq TER(t = -\infty) = TER(t = +\infty) = 1$ 。

综上， $EER \leq TER_{\min} \leq 2EER$  及  $\frac{1}{2}TER_{\min} \leq EER \leq TER_{\min} \leq 1$  得证。

上述结论说明，EER 和  $TER_{\min}$  虽然是两种不同的确认性能指标，但是他们的计算结果相近。根据上面结论，我们可以根据 EER 计算出  $TER_{\min}$  的取值范围，也可以根据  $TER_{\min}$  计算出 EER 的取值范围。

**命题 2. 对所有用户的相似度值进行同样的单调递增变换，系统的 EER（或  $TER_{\min}$ ）保持不变。**

证明：设原始相似度值  $s$ ，单调递增变换  $s' = f(s)$ ，设变换前后的错误接受率分别为  $FAR$  和  $FAR'$ ，变换前后的错误拒绝率分别为  $FRR$  和  $FRR'$ ，则

$$FAR(t) = P(s \geq t | \bar{\lambda}) = P(f(s) \geq f(t) | \bar{\lambda}) = FAR'(f(t))$$

$$FRR(t) = P(s < t | \lambda) = P(f(s) < f(t) | \lambda) = FRR'(f(t))$$

在结果单调递增变换  $f(s)$  前，假定在  $s = t_0$  处为等错误率点，即

$$FAR(t_0) = FRR(t_0) = EER$$

则经过  $f(s)$  变换后， $FAR'(f(t_0)) = FAR(t_0) = FRR(t_0) = FRR'(f(t_0)) = EER$

即变换后，在  $t_0' = f(t_0)$  处为新的等错误率点，等错误率仍为 EER。

所以，对所有相似度值进行同样的单调递增变换，系统的等错误率（EER）保持不变。同样可以证明，系统的最小错误率和（ $TER_{\min}$ ）也保持不变。

**命题 3. 对系统中一个用户  $G_i$  的所有相似度值进行同样的单调递增变换，该用户的 EER（或  $TER_{\min}$ ）保持不变。**

证明过程同上。这一结论是分值归一方法（见第 3 章）的基础。

**命题 4. 系统的  $TER_{\min}$  不小于每个用户  $TER_{\min}^{(i)}, (i = 1, \dots, |G|)$  的数学期望，即：**

$$TER_{\min} \geq \sum_{i=1}^{|G|} P(G_i) TER_{\min}^{(i)}$$

证明：假定系统在  $t_1$  处  $TER$  最小，则

$$\begin{aligned} TER_{\min} &= TER(t_1) \\ &= FAR(t_1) + FRR(t_1) \\ &= \sum_{i=1}^{|G|} P(G_i) \cdot FAR_i(t_1) + \sum_{i=1}^{|G|} P(G_i) \cdot FRR_i(t_1) \\ &= \sum_{i=1}^{|G|} P(G_i) \cdot [FAR_i(t_1) + FRR_i(t_1)] \\ &= \sum_{i=1}^{|G|} P(G_i) \cdot TER_i(t_1) \\ &\geq \sum_{i=1}^{|G|} P(G_i) TER_{\min}^{(i)} \end{aligned}$$

**命题 5. 系统的  $EER$  可能大于、等于或小于每个用户的  $EER$  的数学期望。**

与  $TER_{\min}$  不同，系统的  $EER$  可能大于、等于或小于每个用户  $EER$  的数学期望。现举例说明系统的  $EER$  小于每个用户  $EER$  的数学期望。

表 2-1 一组虚拟相似度示例

相似度	G1	G2	G3
P1	0.8	0.7	0.5
P2	0.9	0.6	0.3
P3	0.2	0.1	0.4

表 2-1 中举例说明了一个由 3 个用户组成的人脸确认系统。参考图像集合为 G1、G2 和 G3。3 幅测试人脸图像 P1、P2 和 P3，其身份分别与 G1、G2 和 G3 对应。根据某种算法计算出的测试图像合参考图像之间的相似度分值。系统性能如表 2-2 所示。

表 2-2 该算法的辨识和确认性能

首选识别率 $R_{T1}$	67%
$EER$	$EER = 0.33$ , $EER_1 = 0.5$ , $EER_2 = 0.5$ , $EER_3 = 0.5$
$TER_{\min}$	$TER_{\min} = 0.5$ , $TER_{\min}^{(1)} = 0.5$ , $TER_{\min}^{(2)} = 0.5$ , $TER_{\min}^{(3)} = 0.5$

所以,  $EER = 0.33 < \frac{1}{3} \sum_{i=1}^3 EER_i = 0.5$ 。同样, 通过举例也可以说明系统的 EER 可能

等于或大于每个用户的 EER 的数学期望。

**命题 6.** 存在两种算法 A 和 B, 使得 A 的辨识性能优于 B, 但 B 的确认性能优于 A。

下面举一组算法 A 和 B 的相似度的例子, 如表 2-3 所示。

表 2-3 一组虚拟相似度示例

算法 A				算法 B			
相似度	G1	G2	G3	相似度	G1	G2	G3
P1	0.9	0.2	0.8	P1	0.6	0.8	0.1
P2	0.1	0.4	0.3	P2	0.2	0.7	0.3
P3	0.5	0.6	0.7	P3	0.4	0.5	0.9

根据表 2-3 中的相似度, 可以计算出 A 和 B 的辨识和确认性能, 如表 2-4。

表 2-4 算法 A 和算法 B 的辨识和确认性能

A	首选识别率 $R_{T1}$	100%
	EER	$EER = 0.33, EER_1 = 0, EER_2 = 0.5, EER_3 = 0.5$
	$TER_{\min}$	$TER_{\min} = 0.5, TER_{\min}^{(1)} = 0, TER_{\min}^{(2)} = 0.5, TER_{\min}^{(3)} = 0.5$
B	首选识别率 $R_{T1}$	67%
	EER	$EER = 0.17, EER_1 = 0, EER_2 = 0.5, EER_3 = 0$
	$TER_{\min}$	$TER_{\min} = 0.17, TER_{\min}^{(1)} = 0, TER_{\min}^{(2)} = 0.5, TER_{\min}^{(3)} = 0$

可见, 在这个使用 3 幅测试图像和 3 幅参考图像的测试中, 算法 A 的辨识性能优于算法 B, 而算法 B 的确认性能优于算法 A。

**命题 7.** 设用户  $i$  的人脸图像与用户  $j$  的人脸模型的相似度模型为  $p_{ij}(s)$ 。当  $i = j$  时,  $p_{ii}(s)$  表示用户  $i$  的类内相似度分布模型; 当  $i \neq j$  时,  $p_{ij}(s)$  表示用户  $i$  的人脸图像与用户  $j$  的人脸模型之间的类间相似度分布模型。又设  $p_{ij}(s)$  满足正态分布  $p_{ij}(s) \sim N_{\mu_{ij}, \sigma_{ij}}(s)$ 。则

(1) 首选识别率  $R_{T1}$  是类内分布均值  $\mu_{ii}$  的单调递增函数, 是类间分布均值  $\mu_{ij}, (j \neq i)$  的单调递减函数, 即

$$\partial R_{T1}/\partial \mu_{i i} > 0, \quad \partial R_{T1}/\partial \mu_{i j} < 0, (i \neq j)。$$

(2) 最小错误率和  $TER_{\min}$  是类内分布均值  $\mu_{i i}$  的单调递增函数，是类间分布均值  $\mu_{i j}, (j \neq i)$  的单调递减函数，是类内分布方差  $\sigma_{i i}$  和类间分布方差  $\sigma_{i j}, (j \neq i)$  的单调递增函数，即

$$\partial TER_{\min}/\partial \mu_{i i} > 0, \quad \partial TER_{\min}/\partial \mu_{i j} < 0, (i \neq j),$$

$$\partial TER_{\min}/\partial \sigma_{i i} < 0, \quad \partial TER_{\min}/\partial \sigma_{i j} < 0, (i \neq j)$$

证明：

(1) 设该系统包含  $M$  个用户，每个用户出现的概率相等。首选识别率  $R_{T1}$  为：

$$R_{T1} = \frac{1}{M} \sum_{i=1}^M \left\{ \int_{-\infty}^{+\infty} p_{i i}(t) \cdot \left[ \prod_{j \neq i} \int_{-\infty}^t p_{i j}(s) ds \right] \cdot dt \right\}$$

因为  $p_{i j}(s)$  满足正态分布  $N_{\mu_{i j}, \sigma_{i j}}(s)$ ，所以

$$R_{T1} = \frac{1}{M} \sum_{i=1}^M \left\{ \int_{-\infty}^{+\infty} N_{\mu_{i i}, \sigma_{i i}}(t) \cdot \left[ \prod_{j \neq i} \int_{-\infty}^t N_{\mu_{i j}, \sigma_{i j}}(s) ds \right] \cdot dt \right\}$$

$R_{T1}$  对类内分布均值  $\mu_{i i}$  的偏微分

$$\begin{aligned} \frac{\partial R_{T1}}{\partial \mu_{i i}} &= \frac{\partial}{\partial \mu_{i i}} \left\{ \frac{1}{M} \sum_{i=1}^M \left\{ \int_{-\infty}^{+\infty} N_{\mu_{i i}, \sigma_{i i}}(t) \cdot \left[ \prod_{j \neq i} \int_{-\infty}^t N_{\mu_{i j}, \sigma_{i j}}(s) ds \right] \cdot dt \right\} \right\} \\ &= \frac{1}{M} \int_{-\infty}^{+\infty} \left[ \frac{\partial}{\partial \mu_{i i}} N_{\mu_{i i}, \sigma_{i i}}(t) \right] \cdot \left[ \prod_{j \neq i} \int_{-\infty}^t N_{\mu_{i j}, \sigma_{i j}}(s) ds \right] \cdot dt \\ &= \frac{1}{M} \int_{-\infty}^{+\infty} \left[ N_{\mu_{i i}, \sigma_{i i}}(t) \cdot 2(t - \mu_{i i}) \right] \cdot \left[ \prod_{j \neq i} \int_{-\infty}^t N_{\mu_{i j}, \sigma_{i j}}(s) ds \right] \cdot dt \\ &= \frac{2}{M} \int_{-\infty}^{+\infty} \left[ N_{0, \sigma_{i i}}(t) \cdot t \right] \cdot \left[ \prod_{j \neq i} \int_{-\infty}^{t + \mu_{i i}} N_{\mu_{i j}, \sigma_{i j}}(s) ds \right] \cdot dt \\ &= \frac{2}{M} \int_{-\infty}^{+\infty} F_1(t) \cdot F_2(t) \cdot dt \end{aligned}$$

其中， $F_1(t) = N_{0, \sigma_{i i}}(t) \cdot t$  为奇函数，且当  $t > 0$  时， $F_1(t) > 0$ 。

$F_2(t) = \prod_{j \neq i} \int_{-\infty}^{t + \mu_{i i}} N_{\mu_{i j}, \sigma_{i j}}(s) ds$  为非负单调递增函数。所以

$$\frac{\partial R_{T1}}{\partial \mu_{i i}} = \frac{2}{M} \int_{-\infty}^{+\infty} F_1(t) \cdot F_2(t) \cdot dt > 0$$

所以，当类内分布均值  $\mu_{i i}$  增大时，首选识别率  $R_{T1}$  增大。

同样可以证明，首选识别率  $R_{T1}$  对类间分布均值  $\mu_{i j}, (j \neq i)$  的偏微分

$$\begin{aligned} \frac{\partial R_{T1}}{\partial \mu_{i j}} &= \frac{\partial}{\partial \mu_{i j}} \left\{ \frac{1}{M} \sum_{i=1}^M \left\{ \int_{-\infty}^{+\infty} N_{\mu_{i i}, \sigma_{i i}}(t) \cdot \left[ \prod_{j \neq i} \int_{-\infty}^t N_{\mu_{i j}, \sigma_{i j}}(s) ds \right] \cdot dt \right\} \right\}, (j \neq i) \\ &= \frac{1}{M} \left\{ \int_{-\infty}^{+\infty} N_{\mu_{i i}, \sigma_{i i}}(t) \cdot \left[ \prod_{k \neq i, k \neq j} \int_{-\infty}^t N_{\mu_{i k}, \sigma_{i k}}(s) ds \right] \cdot \left[ \int_{-\infty}^t N_{\mu_{i j}, \sigma_{i j}}(s) \cdot 2(s - \mu_{i j}) ds \right] \cdot dt \right\} \\ &= \frac{1}{M} \left\{ \int_{-\infty}^{+\infty} N_{\mu_{i i}, \sigma_{i i}}(t) \cdot \left[ \prod_{k \neq i, k \neq j} \int_{-\infty}^t N_{\mu_{i k}, \sigma_{i k}}(s) ds \right] \cdot \left[ \int_{-\infty}^{t+\mu_{i j}} N_{0, \sigma_{i j}}(s) \cdot 2s ds \right] \cdot dt \right\} \\ &= \frac{1}{M} \int_{-\infty}^{+\infty} F_1(t) \cdot F_2(t) \cdot F_3(t) \cdot dt \end{aligned}$$

其中，  $F_1(t) = N_{\mu_{i i}, \sigma_{i i}}(t) > 0$ ，  $F_2(t) = \prod_{k \neq i, k \neq j} \int_{-\infty}^t N_{\mu_{i k}, \sigma_{i k}}(s) ds > 0$ ，

$F_3(t) = \int_{-\infty}^{t+\mu_{i j}} N_{0, \sigma_{i j}}(s) \cdot 2s ds < 0$ 。所以

$$\frac{\partial R_{T1}}{\partial \mu_{i j}} = \frac{1}{M} \int_{-\infty}^{+\infty} F_1(t) \cdot F_2(t) \cdot F_3(t) \cdot dt < 0$$

所以，当类间分布均值  $\mu_{i j}, (j \neq i)$  减小时，首选识别率  $R_{T1}$  增大。

(2) 该系统的最小错误率和  $TER_{\min}$  为

$$TER_{\min} \geq \frac{1}{M} \sum_{i=1}^M TER_{\min}^{(i)} = \frac{1}{M} \sum_{i=1}^M \min \left[ \int_{-\infty}^t p_{i i}(s) ds + \frac{1}{M-1} \sum_{j \neq i} \int_t^{+\infty} p_{j i}(s) ds \right]$$

设在  $t = t_0$  时刻  $TER$  最小，即  $TER_{\min} = TER(t_0)$ ，当满足条件

$$t_0 \leq \mu_{i i}, (i = 1 \dots M) \text{ 且 } t_0 \geq \mu_{i j}, (i = 1 \dots M, j = 1 \dots M, j \neq i) \quad (2-1)$$

时，易证：  $\partial TER_{\min} / \partial \mu_{i i} > 0$ ，  $\partial TER_{\min} / \partial \mu_{i j} < 0, (i \neq j)$ ，

$$\partial TER_{\min} / \partial \sigma_{i i} < 0, \quad \partial TER_{\min} / \partial \sigma_{i j} < 0, (i \neq j)$$

对于任意确认系统不一定能满足(2-1)中的条件，但可以通过分值归一方法调整每个用户的人脸模型（详见第3章）使该条件得到满足。

下面通过一组实验验证上述结论。


对于一个包含  $M$  个用户的人脸确认系统。在上面的推导包含了  $M \times M$  个正态分布模型。我们对其进行简化，假定系统中用户人脸模型是“均匀整齐”的，即所有的类间相似度  $p_{i j}(s), (i \neq j)$  都满足相同的正态分布，并且所有的类内相似度  $p_{i i}(s)$  也满足相

同的正态分布。此时对所有的相似度分值进行归一化，使得类间相似度为标准正态分布，即  $p_{ij}(s) \sim N_{0,1}(s), (i \neq j)$ 。假设归一化后类内相似度分布为  $p_{ii}(s) \sim N_{\mu,\sigma}(s)$ ，则


$$R_{T1} = \int_{-\infty}^{+\infty} N_{\mu,\sigma}(t) \cdot \left[ \int_{-\infty}^t N_{0,1}(s) ds \right]^{M-1} \cdot dt$$

$$TER_{\min} = \min \left[ \int_{-\infty}^t N_{\mu,\sigma}(s) ds + \int_t^{+\infty} N_{0,1}(s) ds \right]$$


给定了一组  $M$ 、 $\mu$  和  $\sigma$  即可计算出一组  $R_{T1}$  和  $TER_{\min}$ ， $TER_{\min}$  与  $M$  的大小无关。




(a)  $M=5$  首选识别率



(b)  $M=20$  首选识别率



(c)  $M=50$  首选识别率



(d)  $TER_{\min}$

图 2-7 一个“均匀整齐”人脸确认系统的  $R_{T1}$  和  $TER_{\min}$

如图 2-7 所示，从(a)(b)(c)中可以看出，首选识别率  $R_{T1}$  随着类内相似度均值的增大而增大。当系统用户数目  $M$  增大时， $R_{T1}$  下降。当类内相似度均值固定，方差减小时， $R_{T1}$  可能增大，也可能减小。从(d)中可以看出  $TER_{\min}$  随着类内相似度均值的增大而减小，随着类内相似度方差的减小而减小。该实验说明了当用户的类内和类间相似度分值的分布发生变化时，辨识指标  $R_{T1}$  和确认指标  $TER_{\min}$  并不遵循同样的变化规律。

## 2.3 典型人脸确认评测协议简介

人脸确认评测过程一般包含两个阶段，第一个阶段要指定数据库和训练、测试集合，将待测算法在指定测试集上运行，输出原始结果。第二个阶段对原始结果进行分析，统计得到性能指标。

本节主要介绍近年来影响最大的三项人脸确认评测 FERET[16][17][18]、FRVT[19][20][21]和 XM2VTS[22][23][24][25][26]中的人脸确认评测协议，并对这些评测的特点和针对性进行探讨。

### 2.3.1 FERET 评测

FERET (Face Recognition Technology Program) 项目是美国国防部的反毒品技术开发计划 (Counterdrug Technology Development Program) 资助的一个人脸识别技术评测项目。该项目在 1993 年到 1997 年期间共组织了三次人脸辨识及确认的性能评测，测试结果公认为反映了当时人脸识别技术的最高学术水平。根据测试报告[18]，南加州大学(USC)的弹性图匹配技术、马里兰大学(UMD)的子空间判别分析方法等人脸识别技术具有最好的确认性能。测试结果也表明了当时的人脸识别算法在光照、姿态、摄像机、年龄发生变化时适应能力比较差。

#### 1. 数据集

FERET 数据库中的图像采集自 1993 年 8 月到 1996 年 7 月。共进行了 15 个阶段的采集，每个阶段持续 1-2 天，采集过程中位置和设置都保持不变。为了保持一致性，所有采集阶段使用相同的采集设备和物理设置。到 1996 年 7 月，共采集 1199 个人的 14126 幅图像，如图 2-8 所示。



图 2-8 FERET 数据库图像示例 (图片引自[16])

#### 2. 评测协议

在 FERET 评测中定义了**目标 (Target) 集**和**查询 (Query) 集**的概念[16]。目标集为所有提供身份的人脸图像组成的集合，FERET96 的目标集为 3323 幅正面人脸图像。查询集为所有不提供身份的人脸图像组成的集合，FERET96 的查询集共有 3816 幅人脸图像，包括目标集中的所有图像，以及一些偏转图像和一些经过处理的图像。



被测算法将查询集中的所有图像同目标集中的所有图像进行比较，得到相似性矩阵。

在统计具体评测结果时，并不直接使用目标集和查询集，而是使用**参考（Gallery）集**和**测试（Probe）集**。参考集和测试集分别是目标集和查询集的子集。针对不同评测目标，可以定义不同的参考集和测试集，以评估算法在不同的测试条件下的性能表现。在参考集中，每个用户只有一幅人脸图像。

设参考集为  $G = \{g_i\}$ ，测试集为  $P = \{p_j\}$ 。如果参考集中只包含一个用户，则对于一幅测试图像  $p_j$ ， $p_j$  身份或者在参考集中（表示为“ig”，即 in gallery），或者不在参考集中（表示为“nig”，即 not in gallery）。当  $p_j$  身份在参考集中时，系统给出“**Yes**”判定的概率定义为击中率（Hit Rate, HR）：

$$HR_i = P_i(Y | ig)$$

当  $p_j$  身份不在参考集中时，系统给出“**Yes**”判定的概率定义为误警率（False Alarm Rate, FAR）：

$$FAR_i = P_i(Y | nig)$$

逐次考察参考集中的每个参考图像  $g_i, i=1,2,...|G|$ ，设阈值为  $t$ ，整个系统的 HR 和 FAR 为：

$$HR = P(Y | ig) = \frac{1}{|G|} \sum_{i=1}^{|G|} P_i(Y | ig)$$

$$FAR = P(Y | nig) = \frac{1}{|G|} \sum_{i=1}^{|G|} P_i(Y | nig)$$

系统根据固定阈值  $t$  判定接受还是拒绝。当阈值  $t$  从  $-\infty$  变化到  $+\infty$  时，得到一系列 HR 和 FAR，依次连接绘制成 ROC 曲线。

### 2.3.2 FRVT 评测

在 FERET 测试之后，出现了很多人脸识别商业系统。为了比较各种商业系统的实际性能，提供详实的人脸识别系统性能资料，美国国防部高级研究计划局、国务院、能源部、联邦调查局和美国国家标准和技术研究所等多家机构分别于 2000 年和 2002 年联合资助了两次针对商业人脸识别产品的 FRVT 评测（Face Recognition Vendor Test）。很多知名的人脸识别商业系统公司参加了该评测。

#### 1. 数据集

FRVT2002 评测分为高计算强度和中等计算强度两种。其中高计算强度测试使用的数据库包含 37,437 人的 121,589 幅图像，全部由美国国务院领事事务局签证服务处提供。每人至少三幅标准的签证照，图像质量很高，采集环境也非常一致。而中等计算

强度测试使用的数据库则包括两部分，一部分来自美国国家标准和技术研究所、美国海军武器研制中心和南佛罗里达大学从 1999 年到 2002 年间采集的静态图像，包括室内和室外图像，最长时间跨度为三年；另一部分则是由德州大学达拉斯分校于 2001 年采集的序列或者静态图像。FRVT2002 图像集合如图 2-9 所示。



图 2-9 FRVT2002 数据库图像示例（图片引自[19]）

## 2. 评测协议

FRVT2002 测试了三类不同的人脸识别任务的性能[19]，分别是身份辨识（Identification，也称闭集识别）、身份确认（Verification）和开集识别（Watch list）。其中，身份辨识和身份确认采用与 FERET96 同样的方法。在开集识别时，测试图像身份可能不在参考集（这里称为 Watch List）中。被测算法要先判定测试图像身份是否属于参考集，如果属于参考集，再识别其身份。FRVT2002 还评测了相似度归一化方法，参加者可针对三类评测分别提交相似度归一化函数。

FRVT2002 中的开集识别是身份辨识和身份确认的推广，它考虑到当测试图像不在参考集中时，系统不应对其进行识别。FRVT2002 定义了 2 个不同的测试（Probe）集。其中，测试集  $P_G$  的身份在参考集中，代表系统的合法用户。测试集  $P_N$  的身份不在参考集中，代表系统的伪冒者。对  $P_G$  中的图像，被测算法应该识别其身份，对  $P_N$  中的图像，被测算法应该给出拒绝判定。

### (a) 开集识别率和错误接受率

开集识别的识别率与拒识阈值  $t$  的大小有关。第  $k$  阶开集识别率，定义为  $P_G$  中的所有图像与对应身份的参考图像的相似度能够通过阈值  $t$ ，并且排在前  $k$  中的概率。

$$P_{TA}(k, t) = \frac{|\{p_j : \text{Rank}(p_j) \leq k, s_{ij} \geq t, id(p_j) = id(g_i)\}|}{|P_G|} \quad \forall p_j \in P_G$$

其中  $p_j$  的阶数为：  $\text{Rank}(p_j) = |\{g_k : s_{kj} \geq s_{ij}, id(g_i) = id(p_j)\}| \quad \forall g_i \in G$

开集识别的错误接受率，定义为 $P_N$ 中的图像与所有参考图像的最大相似度可以通过阈值 $t$ 的比例：

$$P_{FA}(t) = \frac{\left| \left\{ p_j : \max_i s_{ij} \geq t \right\} \right|}{|P_N|} \quad \forall p_j \in P_N \quad \forall g_i \in G$$

给定一个阈值 $t$ ，即可得到一组 $P_{TA}(k)$ 和 $P_{FA}$ 。所以，开集识别的识别率 $P_{TA}$ 可以表示为随阶数 $k$ 和 $P_{FA}$ 变化的二维曲面，如图 2-10(b)所示。此时，闭集识别率曲线相当于开集识别率曲面与平面 $P_{FA}=1$ 的相交线。

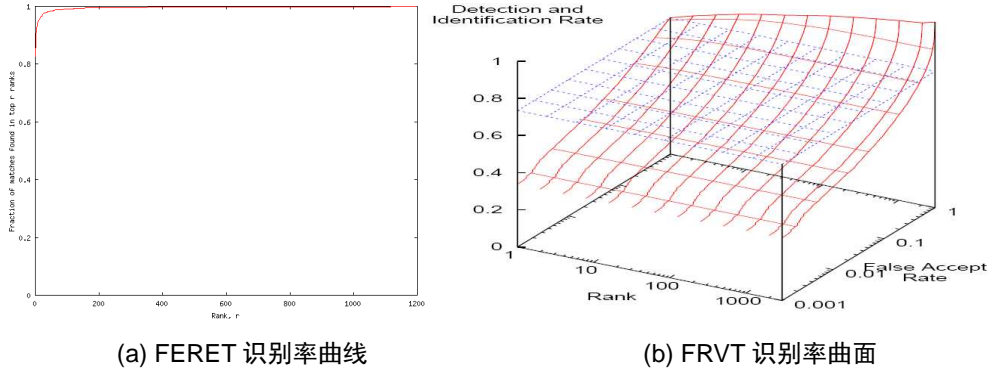


图 2-10 闭集识别和开集识别的识别率曲线

### (b) 开集 ROC 曲线

为了评测开集识别的确认性能，定义以下 2 个指标。

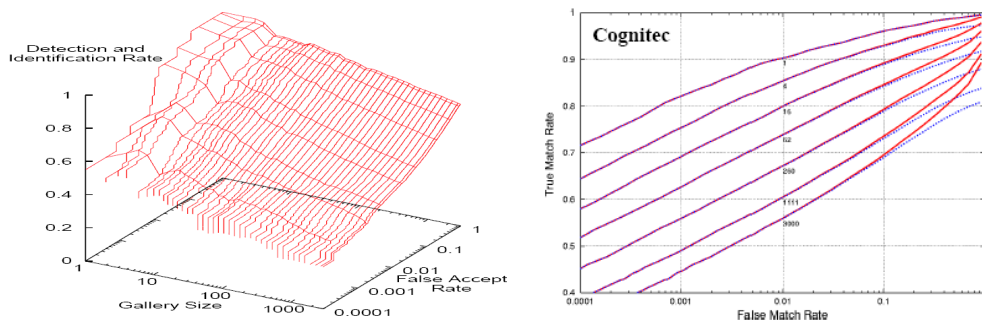
正确接受率 $P_V(t)$ ，为合法用户使用真实身份进行确认时，通过阈值 $t$ 的比例

$$P_V(t) = \frac{\left| \left\{ p_j : s_{ij} \geq t, id(p_j) = id(g_i) \right\} \right|}{|P_G|} \quad \forall p_j \in P_G$$

错误接受率 $P_{FA}(t)$ ，为所有伪冒者入侵事件中，通过阈值 $t$ 的比例

$$P_{FA}(t) = \frac{\left| \left\{ s_j : s_{ij} \geq t \right\} \right|}{|P_N||G|} \quad \forall p_j \in P_N$$

这里所有伪冒者入侵事件，包含了所有伪冒者对所有合法身份的伪冒，所以全部伪冒情况总共有 $|P_N||G|$ 种可能。当参考集的大小 $|G|$ 一定时，给定一个阈值 $t$ ，即可得到一组 $P_V(t)$ 和 $P_{FA}(t)$ 的组合。所以，正确接受率 $P_V(t)$ 可以表示为随 $|G|$ 和 $P_{FA}(t)$ 变化的二维曲面，如图 2-11(a)所示。这个曲面和多个 $|G|=K$ 平面的交线得到在不同参考集规模下的多条 ROC 曲线，如图 2-11(b)所示。



(a) 开集识别的 ROC 曲面

(b) 开集识别中与参考集大小相关的 ROC 曲线

图 2-11 闭集识别和开集识别的 ROC 曲线 (图片(a)引自[21], (b)引自[20])

### 2.3.3 XM2VTS 评测

M2VTS 是欧盟先进通信技术和业务项目 (Advanced Communications Technologies and Services, ACTS) 中的一个子项目, M2VTS 于 1997-1998 年期间进行, 研究多种模式下访问控制问题。XM2VTS 数据库为 M2VTS 数据库的扩展。迄今为止, 在 XM2VTS 数据库上的人脸确认评测共进行三次。第一次与 2000 年 ICPR 会议联合进行, 共有 4 家机构参加评测[24]。第二次与 2003 年 AVBPA 会议联合进行, 共有 7 家机构参与评测[25]。第三次与 2006 年 ICB 会议联合进行, 3 家机构的超过 10 种算法参与评测[26]。

#### 1. 数据集合

XM2VTS 数据库在英国萨里大学采集完成, 包含 295 个人的面部图像和语音数据。全部数据的采集共分 4 个阶段, 在 5 个月内完成, 各阶段的间隔时间相等。每个阶段包含 2 段记录, 每段记录中包含同步的语音和头部旋转序列。全部数据超过 4000G。

在进行人脸确认评测时, 从每个记录中提取一幅正面图像, 每个人得到 8 幅图像, 共计  $295 \times 8 = 2360$  幅。每幅图像的原始尺寸为  $720 \times 576$  像素, 不经过压缩, 以 24 位格式存储, 如图 2-12 所示。



图 2-12 XM2VTS 数据库图像实例 (图片引自[22])

#### 2. 评测协议

评测协议分为训练集、校验集和测试集。训练集用来创建每个合法用户的模型, 校验集用来选取系统参数和阈值, 测试集用来评测算法性能。在 295 个人中, 将 200

个人作为系统合法注册用户，余下 95 个人作为系统伪冒者。

第一种评测协议如图 2-13(a)所示，对于 200 个合法用户，使用前 3 个采集期的各 1 幅图像训练人脸模型，使用前 3 个采集期的另外 3 幅图像估计参数，使用第 4 个采集期的 2 幅图像测试合法认证。在 95 个伪冒者中，25 个人的图像用来进行参数估计，另外 70 个人的图像用来对伪冒者入侵进行测试。综上，在参数估计时，总共使用  $3 \times 200$  种合法测试，和  $8 \times 25 \times 200$  种伪冒测试。在进行测试时，总共使用  $2 \times 200$  种合法测试，以及  $8 \times 70 \times 200$  种伪冒测试。

第二种评测协议如图 2-13(b)所示，对于 200 个合法用户，使用前 2 个采集期内的 4 幅图像训练人脸模型，使用第 3 个采集期的 2 幅图像估计参数，使用第 4 个采集期的 2 幅图像测试合法认证。综上，在参数估计时，总共使用  $2 \times 200$  种合法测试，和  $8 \times 25 \times 200$  种伪冒测试。在进行测试时，总共使用  $2 \times 200$  种合法测试，以及  $8 \times 70 \times 200$  种伪冒测试。

Session	Recording	Clients (200)	Impostors (95)	
1	1	Training	Evaluation (25)	Test (70)
	2	Evaluation		
2	1	Training		
	2	Evaluation		
3	1	Training		
	2	Evaluation		
4	1	Test		
	2			

(a) Configuration 1

Session	Recording	Clients (200)	Impostors (95)			
1	1	Training	Evaluation (25)	Test (70)		
	2					
2	1	Evaluation				
	2					
3	1	Test				
	2					
4	1	Test				
	2					

(b) Configuration 2

图 2-13 XM2VTS 测试协议（图片引自[23]）

XM2VTS 评测中比较不同算法在如下 3 种情况下的错误率和（TER）。

(a) 等错误率点，定义为错误接受率 FAE 和错误拒绝率 FRE 相等的点。

$$T_{FAE=FRE} = (T \mid FAE = FRE)$$

$$TER_{FAE=FRE} = FA_{FAE=FRE} + FR_{FAE=FRE}$$

(b) 错误接受率 FAE 为 0 的点

$$T_{FAE=0} = \arg \min_T (FRE \mid FAE = 0)$$

$$TER_{FAE=0} = FA_{FAE=0} + FR_{FAE=0}$$

(c) 错误拒绝率 FRE 为 0 的点

$$T_{FRE=0} = \arg \min_T (FAE | FRE = 0)$$

$$TER_{FRE=0} = FA_{FRE=0} + FR_{FRE=0}$$

## 2.4 本章小结

本章主要尝试探讨人脸确认的本质问题，在应用背景、分类器设计、性能评价方法等方面对人脸辨识和人脸确认进行了对比，指出了人脸辨识和人脸确认的区别和联系。探讨了脸确认问题的独特性。主要包括：

首先，推导了一些人脸确认评测指标的数学关系，证明了  $EER$  和  $TER_{min}$  虽然是两种不同的衡量标准，但计算结果近似。本章证明了系统的  $EER$  和  $TER_{min}$  与每个用户的  $EER$  和  $TER_{min}$  的关系。这些数学关系是第 3 章分值归一方法的数学基础。

其次，通过建立数学模型，证明了  $R_{TI}$  和  $TER_{min}$  随相似度的类内和类间相似度分布变化的变化规律。在类内和类间相似度分布变化时， $R_{TI}$  和  $TER_{min}$  并不遵从同样的变化规律，这说明一种辨识性能好的算法，未必具有好的确认性能。反之，一种确认性能好的算法，未必具有好的辨识性能。

最后，分析了近年来人脸确认领域重要的三个评测 FERET、FRVT 和 XM2VTS 评测的评测协议。探讨了不同评测的特点和针对性。

## 第3章 分值归一方法

本章我们主要讨论人脸确认系统的阈值设定策略。我们首先分析了“相似度偏移问题”，该问题导致唯一阈值的人脸确认系统性能下降。我们分析了该问题的两种解决方法，用户特定阈值和分值归一。本章通过理论分析，证明了在每个用户只有一幅训练图像时，用户特定阈值与 Z-Norm 分值归一的效果等价，并通过实验进行了验证。本章在 FERET 和 CASPEAL 人脸库上进行实验，实验结果表明，在多数情况下分值归一方法能有效的改进人脸确认系统的性能。

### 3.1 相似度偏移问题

人脸确认系统一般由四部分模块组成：数据采集、特征提取、特征匹配和判定决策[28]。数据采集模块采集所需的人脸图像，特征提取模块处理采集到的原始数据，提取出用于确认的特征。特征匹配模块将提取的特征同系统中人脸模型进行比较，计算出相似度分值。判定决策模块将相似度分值同决策阈值进行比较。如果相似度大于等于该阈值，则判定为合法用户，否则判定为非法用户。固定阈值（Unified Threshold, UT）的人脸确认系统的判定准则为：

如果  $s \geq \theta$  则接受，否则拒绝

相似度  $s$  分为两类，类内相似度和类间相似度。类内（Genuine）相似度代表所有属于同一用户的人脸图像之间的相似度，类间（Imposter）相似度代表所有属于不同用户人脸图像之间的相似度。如图 3-1 所示。




图 3-1 固定阈值系统的类内和类间分布

在进行人脸确认时，许多因素导致相似度分值发生变化。姿态、表情、光照、年龄的变化都会导致属于同一个人的人脸图像之间的相似度降低，甚至小于不同人之间的相似度。系统中不同的用户具有不同的特征，使得不同用户的类内和类间的相似度分布不同。因此，对所有用户使用同样的固定阈值将导致系统性能下降，我们称之为“相似度偏移”问题。如图 3-2 所示，用户 G1 的最佳阈值为  $\theta_1$ 。但是对于用户 G2，类内和类间相似度都向  $s$  轴正向发生偏移，使得 G2 的最佳阈值移动到  $\theta_2$ 。




图 3-2 不同用户具有不同的类内和类间相似度分布

为了解决由“相似度偏移”导致的性能下降问题，我们分析了两种方法：用户特定阈值（Subject Specific Threshold, SST）和分值归一（Score Normalization, SN）[28]。

### 3.2 用户特定阈值

解决“相似度偏移”问题的一种方法是用户特定阈值（Subject Specific Threshold, SST）。在这种方法中，数据库中的每个用户  $G_i$  拥有单独的阈值  $\theta_i$ ，对于用户  $G_i$ ，决策过程重新定义为：

如果  $s \geq \theta_i$  则接受，否则拒绝

用户  $G_i$  的错误接受率和正确接受率可以写成：

$$FAR_i = \int_{\theta_i}^{+\infty} p(s | \bar{\lambda}_i) ds \quad HR_i = \int_{\theta_i}^{+\infty} p(s | \lambda_i) ds$$

其中  $p(s | \bar{\lambda}_i)$  和  $p(s | \lambda_i)$  分别是用户  $G_i$  的类间和类内的相似度分布。如果每个用户出现的概率相等，那么整个系统的 FAR 和 HR 为：

$$FAR = \frac{1}{|G|} \sum_{i=1}^{|G|} FAR_i = \frac{1}{|G|} \sum_{i=1}^{|G|} \int_{\theta_i}^{+\infty} p(s | \bar{\lambda}_i) ds$$

$$HR = \frac{1}{|G|} \sum_{i=1}^{|G|} HR_i = \frac{1}{|G|} \sum_{i=1}^{|G|} \int_{\theta_i}^{+\infty} p(s | \lambda_i) ds$$

对于人脸确认系统，常常要求 FAR 固定为  $t$ ，此时应该调整每个用户的阈值  $\theta_1, \theta_2, \dots, \theta_{|G|}$  来得到 HR 的最大值。根据拉格朗日乘子法，

$$\begin{aligned} F &= HR - K \cdot (FAR - t) \\ &= \frac{1}{|G|} \sum_{i=1}^{|G|} \left[ \int_{\theta_i}^{+\infty} p(s | \lambda_i) ds - K \cdot \left( \int_{\theta_i}^{+\infty} p(s | \bar{\lambda}_i) ds - t \right) \right] \end{aligned}$$

为了得到 HR 的最大值，F 对  $\theta_i$  的微分  $\partial F / \partial \theta_i$  应该等于 0，即



$$\frac{\partial F}{\partial \theta_i} = -\frac{1}{|G|} (p(\theta_i | \lambda_i) - K \cdot p(\theta_i | \bar{\lambda}_i)) = 0$$

所以，最佳的用户特定阈值  $\tilde{\theta}_1, \tilde{\theta}_2, \dots, \tilde{\theta}_{|G|}$  应满足

$$\frac{p(\tilde{\theta}_i | \lambda_i)}{p(\tilde{\theta}_i | \bar{\lambda}_i)} = K, \quad (i=1, 2, \dots, |G|) \quad (3-1)$$

如果进一步假定用户  $G_i$  的类内相似度分值满足高斯分布  $N(\mu_i, \sigma_i)$ ，类间相似度分值满足高斯分布  $N(\bar{\mu}_i, \bar{\sigma}_i)$ ，则当  $K$  取某一个值时，用户特定阈值  $\tilde{\theta}_i$  可以根据  $K, \mu_i, \sigma_i, \bar{\mu}_i, \bar{\sigma}_i$  唯一解得：

$$\tilde{\theta}_i = f(K, \mu_i, \sigma_i, \bar{\mu}_i, \bar{\sigma}_i)$$

### 3.3 分值归一方法

用户特定阈值方法根据每个用户类内和类间相似度的分布，为每个注册用户指定特定的阈值。为了对类内和类间相似度进行建模，每个用户需要多幅图像进行训练。但是，对于许多人脸确认应用，每个用户在数据库中只有一幅人脸图像。这时，无法对类内分布进行建模，难以直接使用 SST 方法。

分值归一方法可以适用于单一参考图像的人脸库。分值归一方法常常用在分类器融合[29]，签名确认[30]，说话人确认[31]等领域，前人的研究表明，分值归一方法在上述领域可以有效的提高系统性能。

在人脸识别领域，Sanderson 等[32]使用基于高斯混合模型(Gaussian Mixture Model)的分类器进行分类，并对类间分布进行建模和分值归一。Perronnin 等[33]使用关系模型进行确认并提出了两种分值归一方法 R-Norm 和 G-Norm。但是，他们的方法也都需要每个用户提供多幅训练图像，以训练高斯模型。在 FRVT2002 评测中[19]，也对分值归一方法进行了评测。

在分值归一化方法中，最终的分值是原始相似度分值、输入样本、用户特定的信息、伪冒者信息等的函数[31]。研究人员提出了多种不同的分值归一方法。其中，Z-Norm 方法使用伪冒者的统计信息（类间信息）进行分值归一

$$s_{znorm} = \frac{s - u_{\bar{\lambda}_i}}{\sigma_{\bar{\lambda}_i}} \quad (3-2)$$

其中， $u_{\bar{\lambda}_i}$  是用户  $G_i$  的类间相似度的均值， $\sigma_{\bar{\lambda}_i}$  是用户  $G_i$  的类间相似度方差。Z-Norm 方法目标是将所有用户得类间相似度分布都归一化为 0 均值 1 方差的分布。然后再使用同样的阈值进行确认。

下面我们将证明，在每个用户只有一幅训练图像的情况下，Z-Norm 方法与简化的

SST 方法近似。在 SST 方法中，最佳的用户特定阈值  $\theta_1, \theta_2, \dots, \theta_{|G|}$  是由用户  $G_i$  的类内和类间相似度分布得到的。在每个用户只有一幅训练图像的情况下，无法得到类内相似度得分分布信息，此时忽略式 (3-1) 中的类内分布项，只使用类间分布项，得到

$$p(\tilde{\theta}_i | \bar{\lambda}_i) = 1/K, \quad (i=1, 2, \dots, |G|)$$

假定类间相似度满足正态分布  $N(\bar{\mu}_i, \bar{\sigma}_i)$ ，则

$$\tilde{\theta}_i = \mu_{\bar{\lambda}_i} + \sigma_{\bar{\lambda}_i} \cdot \sqrt{2\ln(\sigma_{\bar{\lambda}_i} \cdot K) + \ln(2\pi)}, \quad (i=1, 2, \dots, |G|) \quad (3-3)$$

一般地， $\sigma_{\bar{\lambda}_i}$  对所有用户的变化很小（我们将在后面的实验中进行验证），所以  $\sqrt{2\ln(\sigma_{\bar{\lambda}_i} \cdot K) + \ln(2\pi)}$  近似等于常数  $K'$ ，即

$$\tilde{\theta}_i = \mu_{\bar{\lambda}_i} + \sigma_{\bar{\lambda}_i} \cdot K', \quad (i=1, 2, \dots, |G|)$$

$$s \geq \tilde{\theta}_i \Leftrightarrow s \geq \mu_{\bar{\lambda}_i} + \sigma_{\bar{\lambda}_i} \cdot K' \Leftrightarrow \frac{s - \mu_{\bar{\lambda}_i}}{\sigma_{\bar{\lambda}_i}} \geq K' \Leftrightarrow s_{znorm} \geq K'$$

所以，当只能获得类间分布信息时，Z-Norm 方法同简化的 SST 方法近似等价。

### 3.4 用户特定阈值和分值归一实验

我们在两个公共人脸库 FERET[16]和 CAS-PEAL[27]上进行了实验。FERET 人脸库的训练集包含 429 个人的 1002 幅正面人脸图像。4 个测试子集 Fafb、Fafc、Dup.I、Dup.II 分别测试在表情、光照、年龄变化下的人脸辨识和确认性能。CAS-PEAL 人脸库的训练集包含 300 个人，每人 4 幅正面人脸图像，共计 1200 幅图像。6 个测试子集 Accessory、Aging、Background、Distance、Expression、Lighting 分别用来测试在饰物、年龄、背景、距离、表情和光照变化下的人脸辨识和确认性能。

在实验中，所有训练和测试图像都经过同样的预处理过程。首先通过手工标定出两个眼睛中心点的坐标。然后通过图像的平移、旋转和缩放，使所有人脸图像中两个眼睛的中心都位于同样的位置，将每幅图像裁减为  $64 \times 64$  像素，进行直方图均衡化，按行连接成 4096 ( $64 \times 64$ ) 维向量。

我们首先在 CAS-PEAL 人脸库的训练集上进行实验，观察 Z-Norm 方法对类内和类间相似度分布的影响。CAS-PEAL 人脸库的训练集包含 300 个用户，每个用户 4 幅图像。对于每个用户，可以得到 6 个类内相似度分值和 4784 个类间相似度分值。我们使用 Correlation 方法计算相似度分值，并统计每个用户的类内（Genuine）和类间（Imposter）相似度的均值和方差，如图 3-3 所示。




图 3-3 Z-Norm 前后每个用户的类内和类间相似度的均值和方差

在图 3-3 中，横坐标代表用户序号，从 1 到 300。上行两幅图显示了每个用户的原始相似度的均值和方差，绿线表示类内相似度，蓝线表示类间相似度。下行两幅图显示了每个用户经过 Z-Norm 变换后的相似度的均值和方差。从图中可以看出，对于原始相似度分值，类内分布的均值和方差变化都很大，而类间分布的方差却很一致。在经过 Z-Norm 归一化后，类间相似度的均值都变为 0，方差都变为 1。这相当于将图 3-2 中不同用户的相似度都按照类间分布进行对齐，再使用固定阈值进行判定，所以可以有效提高系统的确认性能。

然后，我们在 FERET 数据库的 Fafb 测试子集上进行实验，比较 UT、SST 和 Z-Norm 三种方式的确认效果。先使用 Correlation 方法计算出原始相似度分值。UT 方法直接使用原始相似度分值进行确认；Z-Norm 方法按照公式 (3-2) 进行归一化；SST 方法按照公式 (3-3) 进行计算。我们将三种方法计算出的 ROC 曲线进行比较。如图 3-4 所示，可以清楚的看到，Z-Norm 和 SST 方法的 ROC 曲线非常接近，并且都明显高于 UT 方法的 ROC 曲线。




图 3-4 Fafb 测试子集上 UT、Z-Norm 和 SST 的 ROC 曲线比较

最后，我们在 FERET 和 CAS-PEAL 数据库上进行人脸确认实验，比较 Z-Norm 和 UT 方法进行在不同测试集上的等错误率大小。由于 SST 与 Z-Norm 方法的结果相接近，这里不再测试 SST 方法。在该实验中，我们通过 Correlation、Eigenface 和 Fisherface 三种不同的分类算法计算出相似度分值，再对 UT 和 Z-Norm 结果进行比较。图 3-5 显示了 FERET 人脸库 4 个子库上的等错误率比较结果。图 3-6 显示了 CAS-PEAL 人

脸库 6 个子库上的等错误率比较结果。对于每种分类算法，左侧柱形显示了 UT 方法的等错误率，右侧柱形显示了使用 Z-Norm 归一化后的等错误率。

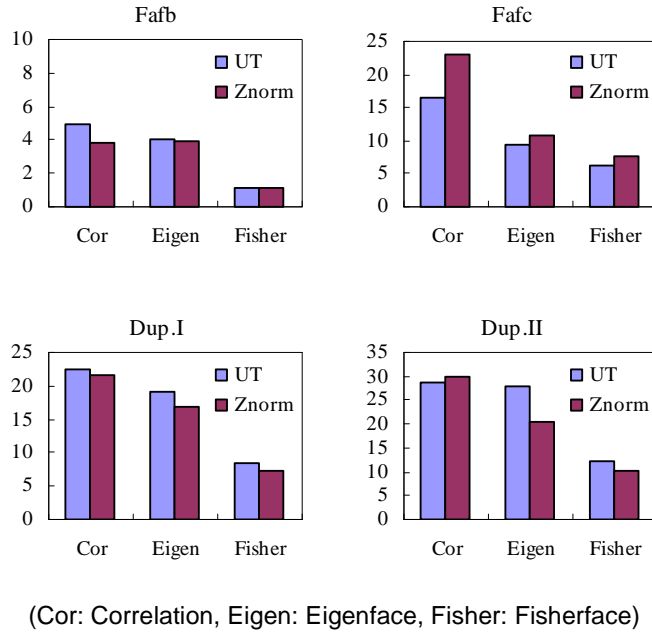


图 3-5 3 种人脸识别算法在 FERET 的 4 个测试子集上 UT 和 Z-Norm 的等错误率

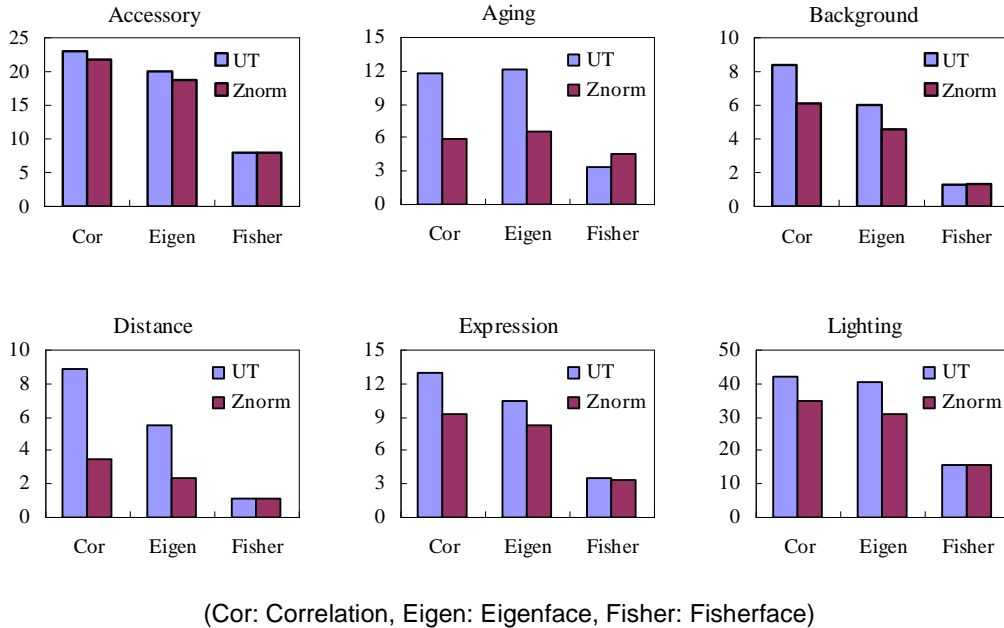


图 3-6 3 种人脸识别算法在 CAS-PEAL 的 6 个测试子集上 UT 和 Z-Norm 的等错误率

从图 3-5 中可以看出，在 FERET 人脸库的 Fafb、Dup.I 和 Dup.II 的测试子集上，Z-Norm 方法能够降低系统的等错误率，提高三种算法的确认性能。而在 Fafc 子集上，三种算法经过 Z-Norm 归一化后性能下降。这主要是由于对用户类间相似度的统计都

是在参考集上进行的。FERET 人脸库的参考集中只包含在均匀光照下采集的人脸图像，所以统计出的类间变化模式也只限于均匀光照情况下。而 Fafc 测试子集包含光照变化下的人脸图像，与参考集上的统计条件不一致，导致 Z-Norm 方法在该集合上失效。从图 3-6 中可以看出，在 CAS-PEAL 库的大多数测试子集上，Z-Norm 都能获得性能提高（只有在 Aging 测试子集上使用 LDA 方法是唯一例外）。

在三种算法中，Z-Norm 对于 Correlation 和 Eigenface 方法大多可以明显提高性能，而对于 LDA 方法，性能提高则并不显著。

### 3.5 本章小结

本章讨论了解决相似度偏移问题的两种方法，用户特定阈值与分值归一。相似度偏移问题主要是由于每个用户的性质不同，以及测试图像的姿态、光照、表情等变化导致的。我们通过理论和实验证明了 Z-Norm 分值归一方法与用户特定阈值的结果相接近。本章在 FERET 和 CAS-PEAL 人脸库上使用不同人脸确认算法进行实验，在多数情况下，Z-Norm 方法与传统的单一阈值方法相比，能有效提高系统的确认性能。



## 第4章 基于 SVM 的人脸确认方法

支持向量机 (SVM) 是一种基于统计学习理论的分类方法。SVM 具有完备的理论基础，以及良好的分类和推广性能。本章主要研究基于 SVM 的人脸确认算法。本章首先介绍统计学习理论和 SVM 的基本原理，然后总结在人脸识别领域应用 SVM 方法的主要文献。我们研究了子空间中的 SVM 确认算法，并在 FERET 人脸库上同多种基准算法进行比较。实验结果表明，在 PCA 子空间中 SVM 分类器能有效提高系统的确认性能，而在 LDA 子空间中由于已经提取了样本的判别信息，再使用 SVM 分类器不能得到明显的性能改善。

本章提出了一种新的基于局部二值模式的 SVM 人脸确认算法 (LBP-SVM)。该方法首先提取图像的 LBP 特征，然后计算出局部统计相似度，并将所有的局部相似度连接成相似度向量，最后使用 SVM 分类器对类内相似度向量和类间相似度向量进行分类。我们在 FERET 人脸库上进行实验，对于所有测试子集，LBP-SVM 方法的确认性能都优于不加权的 LBP 算法。

### 4.1 统计学习理论和支持向量机

#### 4.1.1 统计学习理论

机器学习问题可以形式化表示为：已知变量  $y$  与输入  $x$  之间存在一定的未知依赖关系，即存在一个未知的联合概率  $F(x, y)$ ，根据  $n$  个独立同分布观测样本  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ ，在一组函数  $\{f(x, \omega)\}$  中找一个最优函数  $f(x, \omega_0)$ ，使**期望风险**

$$R(\omega) = \int L(y, f(x, \omega)) dF(x, y) \quad (4-1)$$

最小。其中， $\{f(x, \omega)\}$  称作预测函数集， $\omega \in \Omega$  为函数的广义参数， $L(y, f(x, \omega))$  表示用  $\{f(x, \omega)\}$  对  $y$  进行预测的损失函数。

传统的学习方法基于**经验风险**最小化原则。在实际问题中，由于联合概率  $F(x, y)$  未知，传统的学习方法使用经验风险，即训练样本损失函数的算术平均值，来代替式 (4-1) 中的期望风险，

$$R_{emp}(\omega) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i, \omega)) \quad (4-2)$$

传统的学习方法要求训练样本的数目足够多。只有在样本数趋向无穷大时其性能才有理论上的保证。而在多数实际应用中，样本数目通常是有限的。一味追求训练误

差小并不是总能达到好的预测效果,当训练误差过小时反而可能导致推广能力的下降,这就是过学习问题。过学习问题主要是由于学习样本不充足,以及学习机器设计不合理导致的。在有限维样本情况下,经验风险最小并不一定意味着期望风险最小,学习机器的复杂性不但与系统有关,而且要和有限的学习样本相适应。

统计学习理论 (Statistical Learning Theory) 是一种专门研究小样本情况下机器学习规律的理论。该理论针对小样本统计问题建立了一套新的理论体系,在这种体系下的统计推理规则不仅考虑了对渐近性能的要求,而且追求在现有有限信息的条件下得到最优结果。V. Vapnik 等人从 60 年代开始致力于这方面的研究[34],到 90 年代中期,随着其理论的不断发展和成熟,统计学习理论开始受到越来越广泛的重视。

统计学习理论的一个核心概念是 VC 维 (VC Dimension)。它是描述函数集或学习机器的复杂性,或者说学习能力的一个重要指标。在此概念基础上发展出了一系列关于统计学习的一致性、收敛速度、推广性能等的重要结论。统计学习理论为解决有限样本学习问题提供了一个统一的框架。在这一理论基础上发展出的支持向量机 (Support Vector Machine, SVM) 方法在解决小样本、非线性及高维模式识别问题中表现出了许多特有的优势,并推广到函数拟合等其他机器学习问题中。

#### 4.1.2 最优分类面

SVM 是一种能在训练样本数很小的情况下达到很好的分类推广能力的学习算法。SVM 从线性可分情况下的最优分类面问题发展而来。不失一般性,对于线性可分的二类分类问题,它的目标是产生一个分类器能够对未观察到的例子进行有效分类,即具有良好的泛化能力。如图 4-1 所示,在所有可能将这组数据分割开的线性分类器中,只有一个分类面 (图中  $H$ ) 能够使得离它最近的点与分类面的距离达到最大。所谓最优分类面,就是要求不但能将两类样本无错误地分开,而且要使两类的分类空隙最大。前者是保证经验风险最小,后者是使推广性的界的置信范围最小,从而使期望风险最小。




图 4-1 最优分类面示意图

设判别函数的一般形式为  $g(x) = w \cdot x + b$ , 分类面方程为  $w \cdot x + b = 0$ 。我们将判别



函数进行归一化，使两类所有样本都满足  $|g(x)| \geq 1$ ，这样分类间隔就等于为  $2/\|w\|$ 。

因此，使分类间隔最大等价于使  $\|w\|$ （或  $\|w\|^2$ ）最小。对所有样本正确分类要求满足：

$$y_i[(w \cdot x_i) + b] - 1 \geq 0, \quad i = 1, 2, \dots, n \quad (4-3)$$

满足上述条件且使  $\|w\|^2$  最小的分类面即为最优分类面。最优分类面问题可以表示成在式(4-3)的约束下，求函数

$$\phi(w) = \frac{1}{2} \|w\|^2 = \frac{1}{2} (w \cdot w) \quad (4-4)$$

的最小值。为此，定义如下 Lagrange 函数：

$$L(w, b, \alpha) = \frac{1}{2} (w \cdot w) - \sum_{i=1}^n \alpha_i \{y_i [(w \cdot x_i) + b] - 1\} \quad (4-5)$$

其中， $\alpha_i > 0$  为 Lagrange 系数。我们的问题是对  $w$  和  $b$  求 Lagrange 函数的极小值，

该问题则可以转换成如下对偶问题：在约束条件  $\sum_{i=1}^n y_i \alpha_i = 0$ ， $\alpha_i \geq 0, i = 1, \dots, n$  之下，对

$\alpha_i$  求解以下函数的最大值：

$$Q(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \quad (4-6)$$

求解上述问题后得到的最优分类函数是

$$f(x) = \text{sgn}\{(w^* \cdot x) + b\} = \text{sgn}\left\{\sum_{i=1}^n \alpha_i^* y_i (x_i \cdot x) + b^*\right\} \quad (4-7)$$

其中  $\alpha_i^*$  为式(4-6)求解函数的最优解。根据  $f(x)$  的符号，即可以进行类别的判断。

#### 4.1.3 广义最优分类面

上面的最优分类面是在线性可分的前提下讨论的，在线性不可分的情况下，可以在条件(4-3)中增加一个松弛项  $\xi_i \geq 0$ ，变成

$$y_i[(w \cdot x_i) + b] - 1 + \xi_i \geq 0 \quad (4-8)$$

此时，广义最优分类面问题演化成在式(4-8)的约束下，求下列函数的极小值

$$\phi(w, \xi) = \frac{1}{2} (w \cdot w) + C \left( \sum_{i=1}^n \xi_i \right) \quad (4-9)$$

其中,  $C$  为某个指定的常数, 它实际上控制对错分样本惩罚的程度, 实现在错分样本的比例与算法复杂度之间的折衷。

#### 4.1.4 支持向量机

对于  $N$  维空间中的线性函数, 其 VC 维为  $N+1$ , 所以采用线性分类器具备较好的推广性。在求取最优分类面时, 通过把原问题转化为对偶问题, 计算的复杂度不再取决于空间维数, 而是取决于样本数, 尤其是样本中的支持向量数。这些特点使 SVM 有效解决高维问题成为可能。

对非线性问题, 可以通过非线性变换转化为某个高维空间中的线性问题, 在变换后的空间中求最优分类面。这种变换可能比较复杂, 但在上面的对偶问题中, 不论是寻优函数(4-6)还是分类函数(4-7)都只涉及训练样本之间的内积运算( $x_i \cdot x_j$ )。在高维空间中, 这种内积运算可以用原空间中的函数实现, 甚至没有必要知道变换的形式。只要一种核函数  $K(x_i, x_j)$  满足 Mercer 条件, 它就对应某一变换空间中的内积[48]。因此, 在最优分类面中采用适当的内积函数  $K(x_i, x_j)$  就可以实现某一非线性变换后的线性分类, 而计算复杂度却没有增加, 此时目标函数(4-6)变为

$$Q(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j K(x_i, x_j) \quad (4-10)$$

而相应的判别函数式(4-7)也应变为:

$$f(x) = \text{sgn} \left\{ \sum_{i=1}^n \alpha_i^* y_i K(x_i, x) + b^* \right\} \quad (4-11)$$

这就是支持向量机。支持向量机的基本思路可以概括为: 首先通过非线性变换将输入空间变换到一个高维空间, 然后在这个新空间中求取最优线性分类面, 其中的非线性变换是通过定义适当的内积函数实现的。

SVM 中不同的内积核函数将形成不同的算法, 目前研究最多的核函数主要包括:

线性核函数  $K(x_i, x_j) = x_i^T \cdot x_j$

多项式核函数  $K(x_i, x_j) = (\gamma x_i^T x_j + r)^d \quad \gamma > 0$

径向基 (RBF) 核函数  $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad \gamma > 0$

Sigmoid 核函数  $K(x_i, x_j) = \tanh\left(\frac{b(x \cdot x_i)}{256} - c\right)$

## 4.2 SVM 人脸确认算法概述

由于 SVM 方法是两类问题的分类器，为了解决多类问题。目前存在几种不同的策略实现基于 SVM 的人脸辨识和确认算法，如表 4-1 所示。

表 4-1 SVM 人脸辨识和确认方法

方法	描述
差空间方法	对所有样本两两作差，使多类问题转化为了“类内差”和“类间差”的两类问题。
一对一 One against one	每两类之间训练一个 SVM 分类器，对 N 个类共需要训练 $N(N-1)/2$ 个分类器。使用二叉树或打分法作决策。
一对多 One against rest	在每一类与其它所有类之间训练一个 SVM 分类器，对 N 个类共需要训练 N 个分类器。

### 1. 差空间方法

Phillips 等[37]将人脸**辨识**和**确认**的多类问题转化为了“类内差”和“类间差”的两类问题，“类内差”指属于同一人的人脸图像间的差别，“类间差”指属于不同的人脸图像的差别。图像差别由图像在 PCA 空间的投影系数向量直接相减得到。Phillips 在 FERET 图像库中选取了 200 个人进行实验，训练集和测试集各 100 个人，每人 2 幅图像。Phillips 比较了 PCA 和 SVM 算法的 ROC 曲线，以及两种方法的首选识别率与投影维数之间的变化曲线，SVM 方法的性能明显优于基准 PCA 算法。

### 2. “一对一”方法

G. D. Guo, Stan Li 等[38]使用 SVM 方法进行人脸**辨识**。他们将每个人作为一类，在每两类之间训练一个分类器，这种方法称为一对一（One Against One）方法。对于 N 类问题，共需要构建  $C_N^2$  个分类器。将  $C_N^2$  个分类器构建成一个二叉树，在进行分类时，进行  $N-1$  次比较得到最终的分类结果。G. D. Guo 等在 Cambridge ORL 人脸库（40 人，每人 10 幅图像）上进行实验，比较了 SVM 和 NCC（Nearest Center Classification）两种方法的首选识别率与投影维数之间的变化曲线，SVM 方法明显优于 NCC 方法。在 137 人 1079 幅图像的混合人脸库上的实验也得到类似结论。

### 3. “一对多”方法

Jonsson, Kittler 等[40][41]使用 SVM 方法进行人脸**确认**。他们将一个人作为一类，将其他所有人作为另一类来训练分类器，这种方法称为一对多（One Against Rest）方法。对于 N 类问题，共需要训练 N 个分类器。他们在 XM2VTS 库上比较了不同子空

间 (PCA、LDA)，不同分类器 (欧氏距离最近邻、相关系数最近邻、SVM)，及不同的 SVM 核函数 (线性、多项式、RBF) 的性能。试验结果表明 SVM 方法可以从训练数据学习提取出类判别信息。由于 LDA 空间已经提取了类判别信息，所以在 LDA 空间中使用 SVM 分类器可能会导致过训练。

Bicego 等[42]使用单类 SVM (One-Class SVM, OC-SVM) 方法进行人脸**确认**。OC-SVM 是对单个类进行分类的分类器，它计算包含一类样本的最小闭包，不需要反例训练样本。Becego 等人在 ORL 人脸库上进行实验，将 OC-SVM 和使用不同伪冒者集合训练出的两类 SVM (Binary-Class SVM, BC-SVM) 分类器进行比较，实验结果表明 OC-SVM 与 BC-SVM 最好的结果相当，所以 OC-SVM 能够避免因为伪冒集选择不当导致的性能下降问题。

张宝昌[43]、崔国勤[44]等采用一对多的 SVM 分类器进行人脸**辨识**。他们通过几何变化和灰度变换的方法从生成同一人的多幅图像，以增加正例训练样本数。张宝昌在 ORL 和 FERET 数据库上的试验表明使用 Gabor 特征的 SVM 分类器识别率明显优于 FDA 和 Eigenface 方法。

当前各类 SVM 人脸识别确认算法的优缺点如下：

1. 对于  $N$  个用户的人脸确认系统，“一对多”方法需要训练  $N$  个分类器，“一对一”方法需要设计  $N(N-1)/2$  个分类器。实际的人脸确认系统常常要注册几百、几千甚至更多的用户身份。这时需要分类器数目过多，已经不太可能实现。即使对于少于几十个用户的应用，也存在训练时间过长的问題。

2. “一对一”和“一对多”两种方法都不便于添加用户身份。在向  $N$  个用户的系统中添加一个新用户时，分别需要新训练  $N$  个和 1 个分类器。

3. 基于差空间的 SVM 方法能够克服上述不足。差空间方法只需要训练一个分类器，且不受系统中注册用户变化的影响。但是 Phillips[37]实现的差空间通过像素直接相减得到，当人脸图像的对应部分不能够精确配准时，会导致性能下降。

4. 基于差空间的方法，没有考虑每个用户的独特性，难以为每个用户设定单独阈值。

### 4.3 基于差空间的 SVM 确认算法

对于  $64 \times 64$  像素的人脸图像，人脸图像向量的维数为 4096，常常多于训练样本的个数。所以，人脸确认问题是典型的高维小样本学习问题。SVM 具有良好的分类性能和推广性，使其适用于人脸确认问题。

我们使用差空间方法训练 SVM 分类器。我们先使用子空间方法对原始的人脸图像向量进行降维。PCA 子空间依照最佳描述原则，使降维后的样本保留尽可能多的原始信息，并使得的各维之间不相关。LDA 子空间依据最优分类原则，使各类样本的类内散度尽可能小，类间散度尽可能大。将人脸图像投影到人脸子空间后，对所有样本两

两作差，按照类内差（属于同一个人的人脸向量的差）和类间差（属于不同人的人脸向量的差）分为两类。使用 RBF 核函数的 SVM 分类器对训练两类之间的分类面。

我们在 FERET 人脸库上进行实验。FERET 训练集包含 429 个人的 1002 幅图像，共可以得到 1590 个类内差和 1001412 个类间差。在训练 SVM 分类器时，使用全部类内差作为正例样本，随机选取 2000 个类间差作为反例样本。所有训练和测试图像都进行同样的预处理过程。首先通过手工标定出两个眼睛中心点的坐标。然后通过图像的平移、旋转和缩放，使所有人脸图像两个眼睛的中心位于固定位置，将每幅图像裁减为  $64 \times 64$  像素大小，并进行直方图均衡化。

我们在 FERET 人脸库的 4 个测试子集上 Fafb、Fafc、Dup.I、Dup.II 上进行实验。将 PCA 差空间下的 SVM 算法(PCA-SVM),LDA 差空间下的 SVM 算法(LDA-SVM),与三种基准算法 Correlation (Cor)、Eigenface (PCA)、Fisherface (LDA) 进行比较。各种算法的等错误率如图 4-2 所示，左侧柱形是使用唯一阈值得到的等错误率，右侧柱形是使用 Z-Norm 方法得到的等错误率。

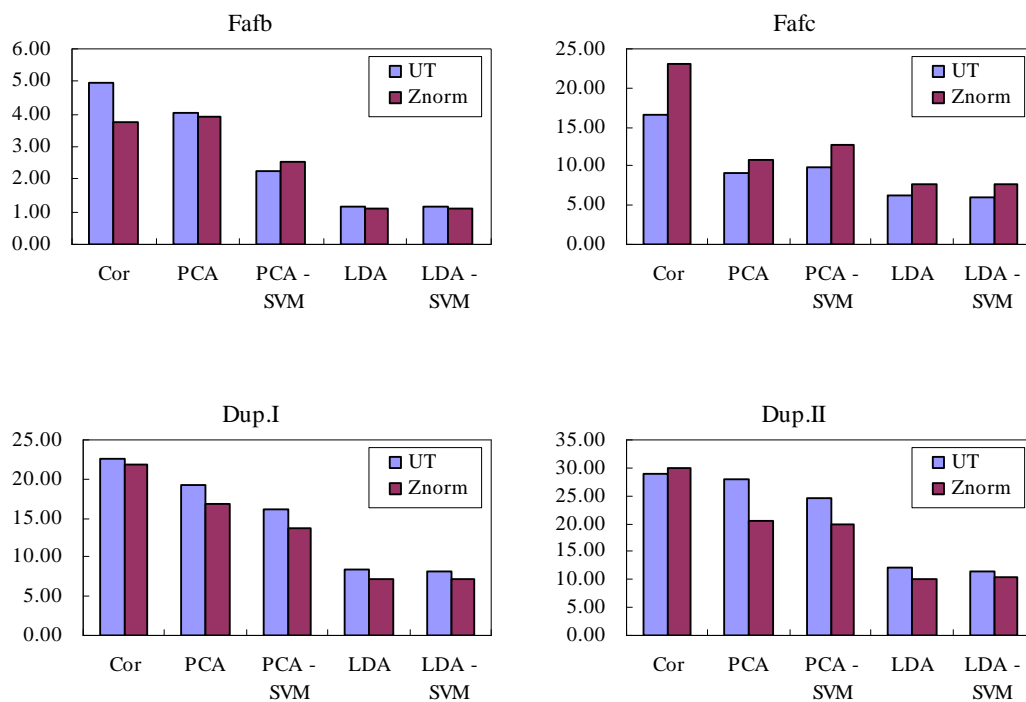


图 4-2 几种人脸确认算法 EER 比较

从图 4-2 中可以看出，在 Fafb、Dup.I、Dup.II 测试集中，PCA-SVM 算法的确认效果明显优于 Eigenface (PCA) 算法。对于 Eigenface 算法，确认判别准则为：

如果  $D(x_1, x_2) \leq \theta$  则接受，否则拒绝

其中  $D(x_1, x_2)$  表示样本  $x_1$  和  $x_2$  之间的距离度量。如果采用欧式距离度量，分类面

函数为  $f(y_{ij}) = \|y_{ij}\| - \theta = \|x_i - x_j\| - \theta$ 。这时，在差空间中的分类面是以原点为中心，半径为  $\theta$  的超球面。

如果采用 L1 距离度量，分类面函数为  $f(y_{ij}) = \|y_{ij}\|_{\infty} - \theta = \|x_i - x_j\|_{\infty} - \theta$ 。这时，差空间中的分类面为以原点为中心，第  $k$  个顶点为  $(\underbrace{0, \dots, 0}_{k-1}, \theta, 0, \dots, 0)$  的超立方体的各面。

PCA 子空间不考虑类别之间的信息，欧式距离和 L1 距离在各个坐标轴方向性质相同，也无法提取不同方向的判别信息。而 SVM 分类器不仅能够提取各方向的判别信息，而且采用非线性分类函数对两类边界进行拟和，所以取得更好的确认性能。

从图 4-2 中还可以看出，在 4 个测试子集中，Fisherface 和 LDA-SVM 算法的等错误率非常接近，这说明 LDA 方法已经提出了各方向的判别信息。在 LDA 子空间中，SVM 分类器与较为简单的欧式距离分类器相比，不能明显改善确认性能。

#### 4.4 基于局部二值模式的 SVM 确认算法

局部二值模式 (Local Binary Pattern, LBP) 特征包含了图像的局部形状和纹理信息。对图像中的一个像素点，LBP 算子将该点的灰度  $f_c$  与周围 8 个像素点的灰度  $f_p$ ，( $p = 0, 1, \dots, 7$ ) 进行比较，比较结果为

$$S(f_p - f_c) = \begin{cases} 1, & f_p \geq f_c \\ 0, & f_p < f_c \end{cases}$$

将  $S(f_p - f_c)$ , ( $p = 0, 1, \dots, 7$ ) 按顺时针方向依次连接，得到 8 位二进制数，大小在 0 到 255 之间，这就是该点的 LBP 特征，如图 4-3 所示。LBP 运算可以表示成：

$$LBP(f_c) = \sum_{p=0}^7 S(f_p - f_c) \cdot 2^p$$




图 4-3 一个像素点的 LBP 运算结果

图像中一个像素点的 LBP 特征的大小，描述了位于该点处的点、线、拐角等形状 [46]。在纹理分析领域，常常利用一定区域内的 LBP 特征的直方图来描述该区域的纹理特性。在进行人脸的表示、检测和识别时，各器官的几何形状、空间位置以及面部的纹理信息都非常重要。因此，使用 LBP 描述人脸时需要先对人脸图像进行分块，在

每个子块中统计局部的 LBP 直方图。最终，将人脸图像表示成由各子块的直方图组成的序列。人脸图像的 LBP 直方图序列的提取过程如图 4-4。




图 4-4 人脸图像 LBP 特征和分块直方图序列提取过程

在人脸识别领域，A. Timo 等[46]研究了基于图像 LBP 特征的人脸辨识方法。他们利用直方图的交、对数似然、卡方统计三种方法计算分块直方图的相似性，对局部直方图匹配结果使用不加权求和及加权求和两种方法，计算整体相似度。他们在 FERET 人脸库上进行实验，结果表明这两种方法都能够达到很好的辨识性能。张文超等[48]将多方向多尺度的 Gabor 小波特征与 LBP 纹理特征相结合，这种新的人脸描述方法在 FERET 图像库上取得了最佳的辨识效果。LBP 特征也应用于人脸检测[49]、表情识别[50]等应用中。

本节中我们将 LBP 特征应用于人脸确认问题，提出一种新的基于 LBP 特征的 SVM 人脸确认方法。在提取 LBP 特征后，将图像分成  $N$  个子块，并统计每个子块的直方图。在比较两幅图像时，计算在对应位置子块的直方图的交，作为局部相似度。将所有子块的局部相似度连接成一个  $N$  维的向量，称之为相似度向量。

我们将属于同一个人的两幅人脸图像之间的相似度向量称之为类内相似度向量 (Intra Class Similarity Vector, ICSV)。将属于不同人的两幅人脸图像之间的相似度向量称之为类间相似度向量 (Extra Class Similarity Vector, ECSV)。使用 SVM 分类器学习 ICSV 和 ECSV 之间的分类面。

我们在 FERET 人脸库上进行实验。人脸图像经过预处理后，裁减为  $64 \times 64$  像素。将图像分为 64 个不相交的子块，每块的大小都为  $8 \times 8$  像素，得到 64 维的相似度向量。FERET 人脸库的训练集包含 429 个人的 1002 幅正面人脸图像，一共可以获得 795 个 ICSV 和 500706 个 ECSV。在实验中，我们使用所有的 ICSV，并随机选取 1000 个 ECSV，使用 RBF 核函数训练 SVM 分类器。我们在 FERTE 图像库 4 个测试子集上将 LBP-SVM 算法与不加权的 RBF 算法进行比较，如图 4-5 所示。左侧柱形是使用唯一阈值得到的等错误率，右侧柱形是使用 Z-Norm 方法得到的等错误率。

从图 4-5 可以看出，在 FERET 人脸库的 4 个测试子集上，LBP-SVM 算法的性能都优于不加权的 LBP 算法。这主要是因为 SVM 算法能够为每个子块学习出不同的重要性。同时，使用控制推广能力的非线性分类面能够更有效的拟和 ECSV 和 ICSV 的边界。

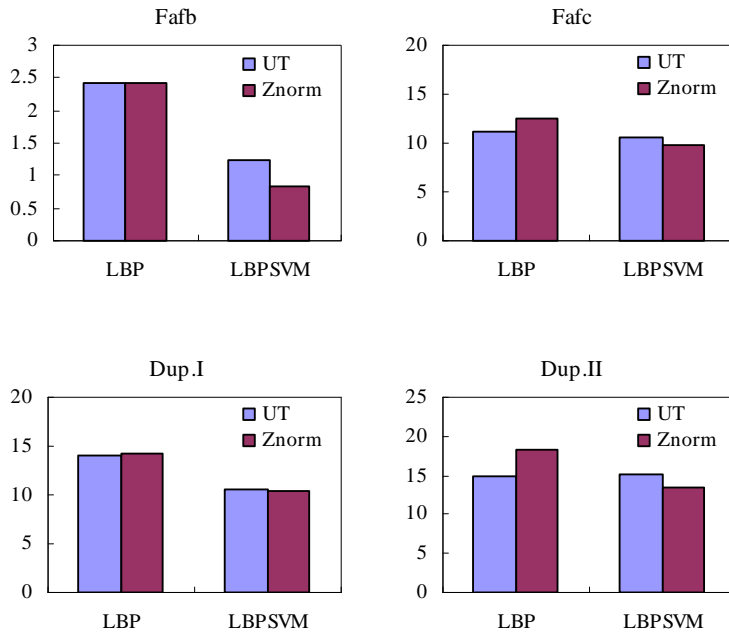


图 4-5 LBP 和 LBP-SVM 算法的 EER 比较

## 4.5 本章小结

本章主要研究基于 SVM 的人脸确认算法。本章首先介绍统计学习理论和 SVM 的基本原理，并总结了在人脸识别领域应用 SVM 方法的主要工作。SVM 是一种两类问题的分类器，为了将 SVM 应用于多类分类问题，提出了差空间、“一对一”、“一对多”三种策略。其中，差空间方法只需要训练一个分类器，当系统的用户发生变化时，分类器不需要改变。本章我们主要研究差空间 SVM 人脸确认算法。

我们通过实验将 PCA 和 LDA 差空间中的 SVM 确认算法同多种基准算法进行比较。在 PCA 子空间中，SVM 方法能够有效提高系统的确认性能。这是因为 SVM 方法能够提取各方向的判别信息，而且采用非线性分类函数对两类边界进行拟合。而在 LDA 子空间中，由于已经提取了样本的判别信息，所以 SVM 分类器不再能提高确认性能。

最后，我们提出了一种新的基于局部二值模式 (LBP) 的 SVM 确认方法，该方法提取图像的 LBP 局部直方图序列，在比较两幅图像时，先对局部直方图进行匹配，得到相似度向量，再使用 SVM 分类器对类内相似度向量和类间相似度向量进行分类。本章在 FERET 人脸上进行实验，在所有测试子集中，LBP-SVM 方法的确认性能都优于不加权的 LBP 算法。



## 第5章 总结

本文主要研究面向确认任务的人脸识别技术。人脸确认是人脸识别领域的重要问题之一。本文首先分析了人脸确认问题的特殊性,将人脸确认与人脸辨识在应用背景、分类器设计、性能评价等方面进行综合比较。我们分析了衡量系统辨识和确认性能的数学指标,推导了“首选识别率”、“等错误率”以及“最小错误率和”之间的数学关系。在文中,我们提出了系统计算辨识和确认性能的数学模型,并使用该模型从理论上证明了,当用户的类内和类间相似度分值的分布发生变化时,系统的确认性能和辨识性能遵循不同的变化规律。也就是说:一种辨识性能好的算法,未必具有好的确认性能。反之,一种确认性能好的算法,也未必具有好的辨识性能。我们还介绍了 FERET、FRVT 和 XM2VTS 三种典型的人脸确认性能评测协议的设计特点。

在本文中,我们探讨了确认系统中的阈值设定策略。针对图像表观变化导致的相似度偏移问题,本文讨论了解决该问题的两种方法:用户特定阈值和分值归一。我们在理论上证明了在每个用户只有一幅训练图像时,用户特定阈值与 Z-Norm 分值归一的效果近似等价,并通过实验验证了这一结论。本文在 FERET 和 CASPEAL 人脸库上使用多种分类算法进行实验,实验结果表明,在多数情况下分值归一方法能有效的提高人脸确认系统的性能。

在本文中,我们研究了子空间中的 SVM 人脸确认算法。我们在 PCA 和 LDA 子空间中,求取样本的类内差和类间差,再使用 SVM 分类器进行分类。在 FERET 人脸库上将 SVM 方法同多种基准算法进行了比较,实验结果表明:在 PCA 子空间中, SVM 方法能够有效提高系统的确认性能。而 LDA 子空间中使用 SVM 分类器不能明显改善确认性能。

本文还提出了一种新的基于局部二值模式(LBP)的 SVM 人脸确认算法。该方法利用 LBP 分块直方图描述图像,在计算两幅图像的相似性时,将对应子块的直方图进行比较,求出局部相似度,将所有块的局部相似度连接成相似度向量。使用 SVM 分类器对类内相似度向量和类间相似度向量进行分类。本文在 FERET 人脸库上进行实验,在各个测试子集上,这种方法都好于不加权的 LBP 算法。

本文的后续工作还将继续研究利用 SVM 分类器和 LBP 特征的人脸确认算法。研究表明,人类的视觉感知过程是一个由整体到细节的过程[51]。在自动人脸识别技术中,也可以将图像的整体相似度计算,分解为先计算局部相似性再进行融合的过程。对于基于 LBP 的 SVM 人脸确认算法,局部区域划分、局部相似性计算,区域间的相关性,以及从局部相似度到整体相似度的融合策略等问题,还有待深入研究。



## 参考文献

- [1] International Biometric Group, The Biometrics Market and Industry Report 2006-2010.  
[http://www.biometricgroup.com/reports/public/market\\_report.html](http://www.biometricgroup.com/reports/public/market_report.html).
- [2] 山世光, 人脸识别中若干关键问题的研究, 博士学位论文, 2004 年 7 月。
- [3] W. Y. Zhao, R. Chellappa, P. J. Phillips, A. Rosenfeld, Face Recognition: A Literature Survey. ACM Computing Surveys (CSUR), Vol. 35, Issue 4, pp. 399-458, Dec. 2003.
- [4] 周杰, 卢春雨, 张长水, 李衍达, 人脸自动识别方法综述, 电子学报, 2000, Vol. 28, No. 4, pp. 102-106.
- [5] J.-L. Dugelay, J.-C. Junqua, C. Kotropoulos, R. Kuhn, F. Perronnin, I. Pitas, Recent Advances in Biometric Person Authentication, Proceedings of International Conference on Acoustics, Speech and Signal Processing (ICASSP), Vol. 4, pp. 4060-4063, 2002.
- [6] W. Bledsoe, Man-Machine Facial Recognition. Panoramic Research Inc. Palo Alto. CA. 1966, Rep PRI: 22.
- [7] N. Roeder, X. B. Li, Accuracy Analysis for Facial Feature Detection, Pattern Recognition, Vol. 29, No. 1, pp. 143-157, Jan. 1996.
- [8] R. Brunelli, T. Poggio, Face Recognition through Geometrical Features, Proceedings of European Conference on Computer Vision (ECCV), 1992, pp. 792-800.
- [9] R. Brunelli, T. Poggio, Face Recognition: Features vs. Templates, IEEE Trans. on Pattern Analysis and Machine Intelligence, Vol. 15, No. 10, pp. 1042-1053, Oct. 1993.
- [10] M. Turk, A. Pentland, Eigenface for Recognition, Journal of Cognitive Neuroscience, Vol. 3, No. 1, pp. 71-86, 1991.
- [11] D. L. Swets, J. Y. Weng, Using Discriminant Eigenfeatures for Image Retrieval, IEEE Trans. on Pattern Analysis and Machine Intelligence. Vol. 18, No. 8, pp. 831-836, 1995.
- [12] P. N. Belhumeur, J. P. Hespanha, D. J. Kriegman. Eigenfaces vs. Fisherfaces: Recognition Using Class Specific Linear Projection, IEEE Trans. on Pattern Analysis and Machine Intelligence, Vol. 19, No. 7, pp. 711-720, Jul. 1997.
- [13] A. M. Martinez, A. C. Kak, PCA versus LDA, IEEE Trans. on Pattern Analysis and Machine Intelligence, Vol. 23, No. 2, pp. 228-233, Feb. 2001.
- [14] P. Penev, J. Atick, Local Feature Analysis: A General Statistical Theory for Object Representation, Network: Computation in Neural Systems, Vol. 7, pp. 477-500, 1996.
- [15] L. Wiskott, J. M. Fellous, N. Kruger, C. Malsburg, Face Recognition by Elastic Bunch Graph Matching, IEEE Trans. on Pattern Analysis and Machine Intelligence, Vol. 19,

- No. 7, pp. 775–779, 1997.
- [16]P. J. Phillips, H. Moon, P. J. Rauss, S. Rizvi, The FERET Evaluation Methodology for Face Recognition Algorithms, IEEE Trans. on Pattern Analysis and Machine Intelligence, Vol. 22, No. 10, pp. 1090-1104, Oct. 2000.
  - [17]S. A. Rizvi, P. J. Phillips, H. Moon, the FERET Verification Testing Protocol for Face Recognition Algorithms. International Conference on Automatic Face and Gesture Recognition (FG), 1998, pp. 48-55.
  - [18]S. A. Rizvi, P. J. Phillips, H. Moon, the FERET Verification Testing Protocol for Face Recognition Algorithms. Technical Report, NISTIR 6281, Oct. 1998.
  - [19]P. J. Philips, P. J. Grother, R. J. Micheals, D. M. Blackburn, E. Tabassi, J. M. Bone, Face Recognition Vendor Test 2002: Evaluation Report, Technical Report, NISTIR 6965, National Institute of Standards and Technology, 2003, <http://www.frvt.org>.
  - [20]P. Grother, Face Recognition Vendor Test 2002 Supplemental Report, Technical Report, NISTIR 7083, Feb. 2004, <http://www.frvt.org>.
  - [21]P. Grother, R. J. Micheals, P. J. Philips, Face Recognition Vendor Test 2002 Performance Metrics, Proceedings of AVBPA, Mar. 2003, pp. 937-945.
  - [22]K. Messer, J. Matas, J. Kittler, J. Luetlin, G. Maitre, XM2VTSDB: the Extended M2VTS Database, Proceedings of AVBPA, Mar. 1999, pp. 72-77.
  - [23]S. Bengio, J. Mariethoz, S. Marcel, Evaluation of Biometric Technology on XM2VTS, Technical Report, IDIAP-RR 01-21, Jul. 2001.
  - [24]J. Matas, M. Hamouz, K. Jonsson, J. Kittler, C. Kotropoulos, A. Tefas, etc., Comparison of Face Verification Results on the XM2VTS Database, Proceedings of the International Conference on Pattern Recognition (ICPR), 2000.
  - [25]K. Messer, J. Kittler, M. Sadeghi, etc., Face Verification Competition on the XM2VTS Database, Proceedings of AVBPA, 2003, pp. 964-974.
  - [26]K. Messer, J. Kittler, J. Short, etc., Performance Characterization of Face Recognition Algorithms and Their Sensitivity to Severe Illumination Changes, Proceedings of ICB, 2006, pp. 1-11.
  - [27]B. Cao, S. G. Shan, X. H. Zhang, W. Gao, Baseline Evaluations on the CAS-PEAL-R1 Face Database, SinoBiometrics 2004, pp. 370-378.
  - [28]A. K. Jain, A. Ross and S. Prabhakar, An Introduction to Biometric Recognition, IEEE Trans. on Circuits and Systems for Video Technology, Special Issue on Image and Video Based Biometrics, Vol. 14, No. 1, pp. 4-20, Jan. 2004.
  - [29]A. K. Jain, K. Nandakumar, A. A. Ross, Score Normalization in Multimodal Biometric Systems, Pattern Recognition, Vol. 38, No. 12, pp. 2270-2285, Dec. 2005.

- [30]J. F. Aguilar, J. O. Garcia, J. G. Rodriguez, Target Dependent Score Normalization Techniques and Their Application to Signature Verification, Proceedings of International Conference on Bioinformatics and its Applications (ICBA), LNCS 3072, pp. 498-504, Dec. 2004.
- [31]C. Barras, J. L. Gauvain, Feature and Score Normalization for Speaker Verification of Cellular Data, Proceedings of IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Vol. 2, pp. 49-52, Hong Kong, Apr. 2003.
- [32]C. Sanderson, K. K. Paliwal: Likelihood Normalization for Face Authentication in Variable Recording Conditions, Proceedings of IEEE International Conference on Image Processing (ICIP), Vol. 1, pp. 301-304, Rochester, Sep. 2002.
- [33]F. Perronnin, J. L. Dugelay, Robust Score Normalization for Relational Approaches to Face Authentication, 12th European Signal Processing Conference, Sep. 2004.
- [34]V. Vapnik, The Nature of Statistical Learning Theory, Springer-Verlag, New York, 1995.
- [35]C. J. C. Burges, A Tutorial on Support Vector Machines for Pattern Recognition, Data Mining and Knowledge Discovery, Vol. 2, No. 2, pp.121-167, 1998.
- [36]边肇祺, 张学工等, 模式识别, 清华大学出版社, 2000 年 1 月第 2 版。
- [37]P. J. Phillips, Support Vector Machines Applied to Face Recognition, Proceedings of the 1998 Conference on Advances in Neural Information Processing Systems II, pp.803- 809.
- [38]G. D. Guo, S. Z. Li, K. Chan, Face Recognition by Support Vector Machines. Proceedings of 4th IEEE FGR, 2000, pp. 96-201.
- [39]B. Heisele, P. Ho, T. Poggio: Face Recognition with Support Vector Machines: Global versus Component-based Approach. Proceedings of ICCV 2001, pp. 688-694.
- [40]K. Jonsson, J. Kittler, Y. P. Li, J. Matas, Support Vector Machines for Face Authentication. Proceedings of the British Machine Vision Conference (BMVC), 1999, pp. 543-553.
- [41]K. Jonsson, J. Kittler, Y. P. Li, J. Matas, Learning Support Vectors for Face Verification and Recognition. FG 2000, pp208-213.
- [42]M. Bicego, E. Grosso, M. Tistarelli. Face Authentication Using One-Class Support Vector Machines. International Workshop on Biometric Recognition Systems, Beijing, Oct. 2005. LNCS 3781, Springer
- [43]B. C. Zhang, W. Gao, S. G. Shan, P. Yang. Discriminant Gaborfaces and Support Vector Machines Classifier for Face Recognition. In ACCV2004, Korea, pp37-42, Jan.27-30, 2004

- [44]G. Q. Cui, W. Gao. Support Vector Machines for Face Recognition with Two-Layer Generated Virtual Data. In Proceeding of International Conference on Pattern Recognition 2004, Cambridge, Vol.3, pp570-573, Aug.2004
- [45]F. Smeraldi, J. Bigun, W. Gerstner, "Support Vector Features and the Role of Dimensionality in Face Authentication" In Proc. of the First International Workshop on Pattern Recognition with Support Vector Machines
- [46]M. Pietikainen, A. Hadid, Texture Features in Facial Image Analysis, International Workshop on Biometric Recognition Systems, Beijing, Oct. 2005. LNCS 3781, pp. 1-8.
- [47]A. Timo, H. Abdenour, and P. Matti. Face Recognition with Local Binary Patterns. In ECCV 2004, pp. 469-481.
- [48]W. C. Zhang, S. G. Shan, W. Gao, X. L. Chen, H. M. Zhang, Local Gabor Binary Pattern Histogram Sequence (LGBPHS): A Novel Non-Statistical Model for Face Representation and Recognition. In ICCV 2005, pp. 786-791.
- [49]A. Hadid, M. Pietikainen, T. Ahonen, A Discriminative Feature Space for Detecting and Recognizing Faces, IEEE Conference on Computer Vision and Pattern Recognition, 2004, Vol. 2, pp 797-804.
- [50]X. Feng, M. Pietikainen, A. Hadid, Facial Expression Recognition with Local Binary Patterns and Linear Programming. Pattern Recognition and Image Analysis, 2005, Vol. 15, pp. 550-552.
- [51]Z. J. Xu, H. Chen, S. C. Zhu, A High Resolution Grammatical Model for Face Representation and Sketching. CVPR(2) 2005, pp. 470-477

## 致 谢

本文的完成，首先要感谢我的导师赵德斌教授。在硕士学习和研究期间，赵老师对我的关心、指导和帮助使我顺利完成学业，完成了该论文的研究和写作。

本文的完成，离不开课题负责人陈熙霖教授和课题组长山世光副研究员对我的指导。陈老师在研究方向和实验细节方面，都给予我大量的指导意见。他严谨的科学精神，对问题的深入见解，令我今后的工作和发展受益匪浅。山世光副研究员帮助我解决学习和研究中遇到的各种问题。在程序开发、研究和写作等方面，教给我大量知识和技能。

本文的完成，还要感谢联合实验室高文教授和各位老师对我的培养和帮助。在人脸识别课题组的学习和工作期间，我得到了曹波、张文超、王建宇、张洪明、马丙鹏、陈杰、柴秀娟、卿来云、张宝昌、杜波、唐杰、苏煜、牛志恒等学长和同学的大量帮助，在此表示衷心的感谢！